ADEN TableRAG additional 평가 최종 보고서

작성 2026-11-13 · C 평가 담당 이정수 · 평가 대상 커밋 `92e8c038`(PR #59 반영) · 질문 세트 additional 30문항

1. 요약

0.899	23/29	23/30	0.775	0
필수 사실 충족률(최종 문맥)	최종 전체 근거 충족 문항	Judge 사실 1점(3회 다수결)	RAGAS Faithfulness	실행 오류

- 기본 TableRAG 경로로 additional 30문항의 답변을 1회 생성하고, 같은 답변을 Judge v3·RAGAS로 3회 채점해 다수결로 정리했다. 다수결 기준 Judge 사실·조건·근거·판단은 23·25·27·27/30이다.
- 검색 평가는 지정 문서·페이지 포함 대신 **질문별 필수 사실이 실제 문맥으로 확인되는지**로 측정했다. 최종 문맥만으로 모든 필수 사실이 확인된 문항은 23/29 (79.3%)로, 기존 지정 근거 기준(15/29 (51.7%))보다 높다. 지정 근거 기준으로는 실패지만 다른 원문으로 충분했던 문항이 8개였다.
- 근거가 충분한데 답변이 틀린 문항(생성·해석)은 4개, 후보 단계에서 필수 사실이 없던 문항(검색·조회)은 1개였다. 5개 문항은 검수 필요 판정이 남아 있고, 미충족 판정이 나온 1개 문항(AS-ADD09)은 원문 확인이 필요하다.

> 이 결과는 커밋 92e8c038 실행의 진단이다. 평가 후 main에 CPU 질의 임베딩 FP32 전환(#64) 등 검색 동작 변경이 병합됐으므로 최신 코드의 성능으로 해석하지 않는다. 답변은 1회 생성 결과이고, Judge 판정이 갈린 항목과 근거 평가의 검수 필요 항목은 사람 검수 전 잠정값이다.

2. 평가 대상과 조건

항목	내용
서비스	DB 우선 TableRAG(기본 서버 경로). 계획 모델·도구(DB 기록 조회, 원문 읽기, SQL 등)·답변 모델
코드	`92e8c038a432c334400619ff38e603be5d863c2e` (미커밋 변경 `False`)
데이터 번들	A 담당 검증 번들, corpus `d6b746e5e64e…` (SHA-256 9개·공식 check 일치)
생성 설정	gpt-6-luna, 추론 강도 medium, 출력 한도 planner 3,500·answer 2,200토큰, 호출당 30초, 재시도 0, 후보 20쪽·최종 8쪽·근거 8,000토큰
질문·정답	additional_questions.json `7ada38ca0380…`, additional.json `c887faa5efb7…` (30문항)
답변 채점	Judge 기준 v3 `5c29900b`, 출력 스키마 judge-output-v2, Judge·RAGAS 모델 gpt-6-luna, 같은 답변 3회 채점 (e1~e3)
근거 평가	필수 사실 v3(29문항 93개), 평가 모델 gpt-6-luna, 후보·최종 문맥 각각 판정
사전 연결 검증	개발 문항 AS-DEV19 1건으로 HTTP 요청→로컬 실행 기록→Langfuse trace→채점 연결을 확인했다(28개 대조 항목 일치, 품질 근거로 쓰지 않음)

3. 평가 방법

3.1 답변 품질

- Judge는 사실·조건·근거·판단 네 항목을 0/1과 사유로 판정한다. 같은 답변을 3회 채점해 항목별 다수결과 일치 수를 기록하고, 갈린 항목은 점수를 덮어쓰지 않고 사람 검수 대상으로 남긴다.
- RAGAS Faithfulness는 답변의 주장이 최종 문맥으로 뒷받침되는 비율이다. 3회 평균과 회차별 값을 함께 본다. 답변이 생략한 사실은 보장하지 않으므로 근거 충족이나 답변 완전성을 대신하지 않는다.

- Langfuse 점수는 게시하지 않았다.

3.2 근거 확보(필수 사실 기준)

- 질문별 필수 사실을 고정하고, 평가 모델에 질문·필수 사실·문맥만 넣어 사실마다 충족·미충족·검수 필요와 출처·원문 구절·사유를 판정했다. 답변과 참고 답변은 넣지 않아 답변 평가와 분리했다.
- 지정 문서가 아니어도 같은 사실을 충분히 뒷받침하면 인정하고, 여러 쪽이 함께 필요한 사실은 조합이 모두 있어야 한다. 사건 질문은 같은 사건인지, 규정 질문은 적용 대상·시점·효력·예외가 맞는지 확인한다.
- 평가 모델이 낸 구절이 그 출처 본문에 실제로 있는지 코드로 다시 확인하고, 없으면 검수 필요로 바꿨다. 검수 필요와 평가 불가는 분모에서 빼지 않고 충족이 아닌 것으로 셌다.
- 후보 문맥은 검색·DB 조회 후보 전체(하이브리드 20쪽, DB 조회 5쪽), 최종 문맥은 답변 모델에 실제 전달된 페이지다. 최종 문맥은 후보의 일부이므로 최종에서 충족된 사실은 근거 출처가 후보에도 있으면 후보에서도 충족으로 본다.

3.3 필수 사실 확정 절차

버전	내용	사실 수
초안	정답 데이터의 required_facts(AS-ADD03은 리뷰 제안 3개)	77
1차 검토	질문·참고 답변·원문만 보고 유지·수정·분리·삭제·추가를 제안(LLM 기반 검토, 생성 답변·점수 미제공). 근거 구절 142개가 원문과 일치함을 확인	-
v1	요건을 줄이거나 늘리지 않는 변경(유지·분리)만 반영	103
v2	보류한 삭제 9·추가 1·수정 10건을 사람이 일괄 수락	95
v3(최종)	수정 10건 개별 검토, AS-ADD13 F2 문구 보완	95

v3 사실의 판정 경로	개수
1차 검토 분리(사람 미확인)	49
1차 검토 유지(사람 미확인)	35
개별 검토 후 수락(2026-11-13)	9
개별 검토 후 문구 보완 수락(2026-11-13)	1
사람 일괄 수락(2026-11-13, 개별 검토 없음)	1
삭제(사람 일괄 수락)	9

사실이 바뀌지 않은 문항은 이전 버전의 판정을 재사용했다(평가 변동과 기준 변경 효과를 섞지 않기 위해). v3 판정 구성: fact-support-v2-changed 13문항, fact-support-v1 15문항, fact-support-v3-add13 1문항.

4. 결과: 답변 품질

항목(3회 다수결)	1점	평가 대상	3회 일치
Judge 사실	23	30	26/30
Judge 조건	25	30	25/30
Judge 근거	27	30	29/30
Judge 판단	27	30	28/30
RAGAS Faithfulness(문항별 3회 평균의 평균)			0.775 (회차 차이 0.2 이상 9문항)
Hit@8 · Recall@8(지정 문서 기준, 참고)			1.000 · 0.902 (29문항)

회차	사실	조건	근거	판단	Faithfulness
e1	0.767	0.867	0.900	0.900	0.786
e2	0.700	0.800	0.900	0.900	0.782
e3	0.767	0.867	0.931	0.967	0.756

판정이 회차마다 갈린 항목은 12건이다: AS-ADD02 조건(1/0/0), AS-ADD03 사실(1/0/1), AS-ADD06 조건(0/0/1), AS-ADD06 판단(0/0/1), AS-ADD09 판단(0/0/1), AS-ADD10 조건(1/0/1), AS-ADD12 근거(0/0/not_applicable), AS-ADD13 사실(0/0/1), AS-ADD15 조건(0/1/0), AS-ADD18 사실(1/1/0), AS-ADD29 사실(1/0/1), AS-ADD29 조건(1/0/1). 다수결 값을 쓰되 사람 검수 전 잠정값이다.

Faithfulness 회차 차이가 큰 문항: AS-ADD03, AS-ADD07, AS-ADD10, AS-ADD11, AS-ADD12, AS-ADD19, AS-ADD25, AS-ADD27, AS-ADD29. 평균만으로는 이 변동이 드러나지 않는다.

상태와 기대 행동

상태 분포: abstained 1, answered 28, needs_clarification 1. 기대 행동과 다른 문항은 다음과 같다.

문항	기대 행동	실제 상태	허용 라벨 포함	Judge 판단(다수결)
AS-ADD06	answer	abstained	아니오	0 (2/3)
AS-ADD13	abstain	answered	예	1 (3/3)
AS-ADD15	abstain	answered	예	0 (3/3)
AS-ADD16	abstain	answered	예	1 (3/3)

5. 결과: 근거 확보(필수 사실 기준)

지표	v3(최종)	v1(참고)	검수 필요 사실(v3)	미충족 사실(v3)
필수 사실 충족률(최종 문맥)	0.899	0.922	6	3
필수 사실 충족률(후보 문맥)	0.911	0.945	6	2
후보 전체 근거 충족률	23/29 (79.3%)	25/29 (86.2%)		
최종 전체 근거 충족률	23/29 (79.3%)	24/29 (82.8%)		
기존 지정 근거 전부 포함(참고)	15/29 (51.7%)	같음		

v3가 v1보다 낮은 주된 이유는 AS-ADD03이다. 개별 검토로 수락한 문구가 이번 실행 문맥에 없는 담당 팀 이름을 요구해 검수 필요가 됐다. 그 밖의 차이는 사실 삭제로 분모가 바뀌었거나 재평가한 문항의 판정 변동이다.

실패 원인 분류

분류	문항 수	문항	의미
근거 충분·답변 정확	19	AS-ADD01, AS-ADD04, AS-ADD05, AS-ADD07, AS-ADD08, AS-ADD11, AS-ADD16, AS-ADD17, AS-ADD18, AS-ADD19, AS-ADD20, AS-ADD21, AS-ADD22, AS-ADD24, AS-ADD25, AS-ADD26, AS-ADD27, AS-ADD28, AS-ADD30	최종 문맥에 필수 사실이 모두 있고 Judge 사실·조건 다수결이 1
검수 필요(후보)	5	AS-ADD02, AS-ADD03, AS-ADD06, AS-ADD10, AS-ADD29	후보 단계 판정에 검수 필요가 남음
생성·해석	4	AS-ADD13, AS-ADD14, AS-ADD15, AS-ADD23	최종 근거는 충분하나 답변이 틀림(Judge 사실 또는 조건 0)
검색·조회	1	AS-ADD09	후보 문맥에도 필수 사실이 없음

지정 근거 기준으로는 실패지만 실제 문맥의 다른 원문으로 필수 사실이 모두 확인된 문항(정답 출처 목록의 한계): 8개 — AS-ADD01, AS-ADD05, AS-ADD07, AS-ADD14, AS-ADD19, AS-ADD21, AS-ADD25, AS-ADD27.

6. 문항별 결과

근거 표시: O 충족, X 미충족, ? 검수 필요. Judge는 사실·조건·근거·판단의 3회 다수결이며, 3회가 모두 같지 않을 때만 일치 수를 괄호로 붙였다(split은 동률). 경로는 첫 검색 경로(hybrid 하이브리드 검색, records DB 기록 조회).

문항	경로	상태	Judge	Faith.	사실	후보	최종	근거 분류	지정
AS-ADD01	hybrid	answered	1·1·1·1	0.80	3	000	000	근거 충분·답변 정확 · 다른 출처로 충분	0
AS-ADD02	hybrid	answered	1·0(2/3)·0·1	0.67	3	0??	?X?	검수 필요(후보)	0
AS-ADD03	hybrid	answered	1(2/3)·1·1·1	0.70	2	0?	0?	검수 필요(후보)	0
AS-ADD04	hybrid	answered	1·1·1·1	0.83	2	00	00	근거 충분·답변 정확	1
AS-ADD05	hybrid	answered	1·1·1·1	0.84	2	00	00	근거 충분·답변 정확 · 다른 출처로 충분	0
AS-ADD06	hybrid	abstained	1·0(2/3)·1·0(2/3)	0.68	3	00?	00?	검수 필요(후보)	0
AS-ADD07	hybrid	answered	1·1·1·1	0.65	2	00	00	근거 충분·답변 정확 · 다른 출처로 충분	0
AS-ADD08	hybrid	answered	1·1·1·1	0.86	2	00	00	근거 충분·답변 정확	1
AS-ADD09	hybrid	answered	0·1·1·0(2/3)	0.82	6	00XX00	00XX00	검색·조회	0
AS-ADD10	hybrid	answered	0·1(2/3)·1·1	0.63	2	?0	?0	검수 필요(후보)	0
AS-ADD11	hybrid	answered	1·1·1·1	0.83	2	00	00	근거 충분·답변 정확	1
AS-ADD12	hybrid	needs_clarification	0·0·0(2/3)·1	0.92	-	확인 질문(근거 평가 대상 아님)			-
AS-ADD13	hybrid	answered	0(2/3)·1·1·1	0.93	5	00000	00000	생성·해석	1
AS-ADD14	hybrid	answered	0·1·1·1	0.83	3	000	000	생성·해석 · 다른 출처로 충분	0
AS-ADD15	hybrid	answered	0·0(2/3)·1·0	0.86	3	000	000	생성·해석	1
AS-ADD16	records	answered	1·1·1·1	0.89	4	0000	0000	근거 충분·답변 정확	1
AS-ADD17	hybrid	answered	1·1·1·1	0.93	3	000	000	근거 충분·답변 정확	1
AS-ADD18	records	answered	1(2/3)·1·1·1	0.90	3	000	000	근거 충분·답변 정확	1
AS-ADD19	hybrid	answered	1·1·1·1	0.79	5	00000	00000	근거 충분·답변 정확 · 다른 출처로 충분	0
AS-ADD20	records	answered	1·1·1·1	0.83	4	0000	0000	근거 충분·답변 정확	1
AS-ADD21	hybrid	answered	1·1·1·1	0.28	4	0000	0000	근거 충분·답변 정확 · 다른 출처로 충분	0
AS-ADD22	records	answered	1·1·1·1	0.95	3	000	000	근거 충분·답변 정확	1
AS-ADD23	hybrid	answered	0·0·0·1	0.92	4	0000	0000	생성·해석	1
AS-ADD24	records	answered	1·1·1·1	0.88	3	000	000	근거 충분·답변 정확	1
AS-ADD25	hybrid	answered	1·1·1·1	0.63	4	0000	0000	근거 충분·답변 정확 · 다른 출처로 충분	0
AS-ADD26	records	answered	1·1·1·1	0.80	2	00	00	근거 충분·답변 정확	1
AS-ADD27	hybrid	answered	1·1·1·1	0.39	3	000	000	근거 충분·답변 정확 · 다른 출처로 충분	0

AS-ADD28	records	answered	1·1·1·1	0.88	4	0000	0000	근거 충분·답변 정확	1
AS-ADD29	hybrid	answered	1(2/3)·1(2/3)·1·1	0.48	4	?000	?000	검수 필요(후보)	0
AS-ADD30	records	answered	1·1·1·1	0.82	3	000	000	근거 충분·답변 정확	1

7. 운영 지표

항목	값
생성 시간	합계 757초, 문항 중앙값 22.7초, 최대 97.6초(순차 실행)
생성 토큰	입력 791,568 / 출력 18,694 (사용량 완전 기록 30/30)
모델 호출	92회(planner 62, answer 30), 실제 재시도 0
검색 경로	hybrid 22, records 8, SQL 호출 0
Judge 채점 토큰(회차별 입력/출력)	210,876/33,015 · 210,876/32,361 · 210,876/30,453. RAGAS 토큰은 기록되지 않음
근거 평가 토큰(v3 판정 기준)	입력 408,854 / 출력 40,491

8. 한계와 후속 작업

확인된 한계

- 답변은 1회 생성 결과로, 같은 질문에 대한 생성 변동은 반영되지 않았다.
- 30문항 모두 SQL 호출이 0건이었다. 이 결과로는 SQL 조회 경로의 품질을 판단할 수 없다.
- Judge v3의 조건 항목에는 서로 충돌하는 규칙 두 문장이 있어 반복 채점 변동의 원인이 된다. 평가 동안 기준을 고정했다.
- 필수 사실 v3 중 84개는 1차 검토 결과를 사람 확인 없이 반영했고, 삭제 9건은 개별 검토 없이 일괄 수락했다.
- 답변 생성·Judge·RAGAS·근거 평가·필수 사실 1차 검토가 모두 같은 제공사 모델이라 판정의 독립성에 한계가 있다.
- 공통 보고서의 재시도 수는 TableRAG의 planner 호출을 재시도로 센다(실제 0인데 62로 표시). RAGAS 토큰은 기록되지 않는다.
- 평가 후 검색 동작을 바꾸는 변경(#64 CPU 질의 임베딩 FP32 등)이 main에 병합됐다.

남은 작업

- 근거 평가 검수 필요 5문항(AS-ADD02, AS-ADD03, AS-ADD06, AS-ADD10, AS-ADD29), 미충족 판정 원문 확인 1문항(AS-ADD09), Judge 판정이 갈린 12건의 사람 검수
- 검수 결과를 반영한 필수 사실 확정과 해당 문항 재평가
- 최종 채택 수치는 기준을 고정한 뒤 최신 main으로 다시 생성해 확인할지 팀 결정
- Langfuse 점수 게시 방식(최종 평가 세트) 결정

부록. 재현 정보

항목	값
실행 기록 runs.jsonl	`sha256:5303419256c6b52a6ec05b050b7478a737c776f1699f398286e892dd942ce273`
필수 사실 v3	`sha256:fea0f885c459dbe1f5ef3370a2db1369de7cd79a6f06468ae68c61af1421d845`
근거 평가 프롬프트	`sha256:da5c4bbad37d5c256a73105cc0e3c1bdc8951d0808732e6ff9d5193613741107`

Judge 프롬프트	`sha256:5c29900bc2f7c590358c8fc4c545a96a2ac5e8226d6d9406e35dec35de049cc4`
관련 PR	Somali-AI-Pirates/ADEN #54(HTTP 채점 연결), #55(평가 설정 정리), #62(additional 평가 결과), #63(근거 평가기)
도구	app.evaluation.scripts.run_table_rag(run·grade), experimental/Damsebi/fix_compare.py(3회 다수결), fact_support.py(근거 평가), fact_support_report.py(집계)

참고 답변 원문과 원본 문서 구절은 이 보고서에 넣지 않았다.