ADEN TableRAG additional 평가 최종 보고서

작성 2026-11-13 · C 평가 담당 이정수 · 평가 대상 커밋 `92e8c038`(PR #59 반영) · 질문 세트 additional 30문항

1. 요약

0.911	24/29	23/30	0.775	0
필수 사실 충족률(최종 문맥, 검수 반영)	최종 전체 근거 충족 문항(검수 반영)	Judge 사실 1점(3회 다수결)	RAGAS Faithfulness	답변 생성 오류

- 기본 TableRAG 경로로 additional 30문항의 답변을 1회 생성하고, 같은 답변을 Judge v3·RAGAS로 3회 채점해 다수결로 정리했다. Judge 사실·조건·근거·판단은 23·25·27·27/30이다.
- 검색 평가는 지정 문서·페이지 포함 대신 **질문별 필수 사실이 실제 문맥으로 확인되는지**로 측정했다. 평가 대상은 29문항 93개 사실이다. 검수 판정을 반영하면 최종 문맥만으로 모든 필수 사실이 확인된 문항이 24/29 (82.8%)다 (평가기 판정만으로는 23/29). 기존 '지정 근거 전부 포함' 문항 수 15/29 (51.7%)보다 높다.
- '지정 근거 전부 포함'을 통과하지 못했지만 최종 문맥이 모든 필수 사실을 뒷받침한 문항이 9개다. 이 중 7개는 지정 페이지 일부로 충분했고 2개는 지정 밖 페이지를 활용했다. 지정 페이지를 모두 요구하면 충분한 문맥도 실패로 셀 수 있다.
- 필수 사실 근거가 검색되지 않은 문항(검색·조회)은 3개다. 근거는 충분하지만 기존 답변 Judge를 통과하지 못한 문항은 5개이며, 이 중 실제 생성 오류로 확인된 것은 AS-ADD23이다.

> 이 결과는 커밋 92e8c038 실행의 진단이다. 평가 후 main에 CPU 질의 임베딩 FP32 전환(#64) 등 검색 동작 변경이 병합됐으므로 최신 코드의 성능으로 해석하지 않는다. 답변은 1회 생성 결과이며, 남은 검수 항목과 Judge 판정이 갈린 항목은 사람 검수 전 잠정값이다.

2. 평가 대상과 조건

항목	내용
서비스	DB 우선 TableRAG(기본 서버 경로). 계획 모델·도구(DB 기록 조회, 원문 읽기, SQL 등)·답변 모델
코드	`92e8c038a432c334400619ff38e603be5d863c2e (미커밋 변경 False)`
데이터 번들	A 담당 검증 번들, corpus `d6b746e5e64e...` (SHA-256 9개·공식 check 일치)
생성 설정	gpt-6-luna, 추론 강도 medium, 출력 한도 planner 3,500·answer 2,200토큰, 호출당 30초, 재시도 0, 후보 20쪽·최종 8쪽·근거 8,000토큰
질문·정답	additional_questions.json `7ada38ca0380...`, additional.json `c887faa5efb7...` (30문항)
답변 채점	Judge 기준 v3 `5c29900b`, 출력 스키마 judge-output-v2, Judge·RAGAS 모델 gpt-6-luna, 같은 답변 3회 채점 (e1~e3). 정답 파일의 원래 참고 정답 기준
근거 평가	필수 사실 v4(29문항 93개, 확인 질문 AS-ADD12 제외), 평가 모델 gpt-6-luna, 후보·최종 문맥 각각 판정, 검수 판정 3건(사실·문맥 6건) 겹쳐 적용
사전 연결 검증	개발 문항 AS-DEV19 1건으로 HTTP 요청→로컬 실행 기록→Langfuse trace→채점 연결을 확인했다(28개 대조 항목 일치, 품질 근거로 쓰지 않음)

3. 평가 방법

3.1 답변 품질

- Judge는 사실·조건·근거·판단 네 항목을 0/1과 사유로 판정한다. 같은 답변을 3회 채점해 항목별 다수결과 일치 수를 기록하고, 갈린 항목은 점수를 덮어쓰지 않고 사람 검수 대상으로 남긴다.
- RAGAS Faithfulness는 답변의 주장이 최종 문맥으로 뒷받침되는 비율이다. 답변이 생략한 사실은 보장하지 않으므로 근거 충족이나 답변 완전성을 대신하지 않는다.
- Langfuse 점수는 게시하지 않았다.

3.2 근거 확보(필수 사실 기준)

- 질문별 필수 사실을 고정하고, 평가 모델에 질문·필수 사실·문맥만 넣어 사실마다 충족·미충족·검수 필요와 출처·원문 구절·사유를 판정했다. 답변과 참고 답변은 넣지 않아 답변 평가와 분리했다.
- 지정 문서가 아니어도 같은 사실을 충분히 뒷받침하면 인정하고, 여러 쪽이 함께 필요한 사실은 조합이 모두 있어야 한다. 사건 질문은 같은 사건인지, 규정 질문은 적용 대상·시점·효력·예외가 맞는지 확인한다.
- 평가 모델이 낸 구절이 그 출처 본문에 실제로 있는지 코드로 다시 확인하고, 없으면 검수 필요로 바꿨다. 검수 필요와 평가 불가는 분모에서 빼지 않고 충족이 아닌 것으로 셌다.
- 필수 사실 충족률은 문항별 충족 비율을 먼저 구한 뒤 문항 평균한 값(매크로 평균)이다.
- 원문 위치와 문맥 포함 여부를 대조한 검수 판정은 원래 판정을 바꾸지 않고 겹쳐 적용했다. 보고서는 평가기 판정과 검수 반영 결과를 함께 보인다.

3.3 필수 사실 확정 절차

버전	내용	사실 수
초안	정답 데이터의 required_facts(AS-ADD03은 리뷰 제안 3개)	77
1차 검토	질문·참고 답변·원문만 보고 유지·수정·분리·삭제·추가를 제안(LLM 기반 검토, 생성 답변·점수 미제공). 근거 구절 142개가 원문과 일치함을 확인	-
v1	요건을 줄이거나 늘리지 않는 변경(유지·분리)만 반영	103
v2	보류한 삭제 9·추가 1·수정 10건을 일괄 수락	95
v3	수정 10건 개별 검토, AS-ADD13 F2 문구 보완	95
v4(최종)	AS-ADD03 F2에서 회신 발신 부서 의무 제거(완료 회신 요구는 유지)	95

v4 사실의 판정 경로	개수
1차 검토 분리(사람 미확인)	49
1차 검토 유지(사람 미확인)	35
개별 검토 후 수락(2026-11-13)	8
검토 의견 반영 문구 수정(2026-11-13)	1
개별 검토 후 문구 보완 수락(2026-11-13)	1
사람 일괄 수락(2026-11-13, 개별 검토 없음)	1
삭제(일괄 수락)	9

사실이 바뀌지 않은 문항은 이전 버전의 판정을 재사용했다(평가 변동과 기준 변경 효과를 섞지 않기 위해). v4 판정 구성: fact-support-v2-changed 12문항, fact-support-v1 15문항, fact-support-v4-add03 1문항, fact-support-v3-add13 1문항.

4. 결과: 답변 품질

항목(3회 다수결)	1점	평가 대상	3회 일치
Judge 사실	23	30	26/30
Judge 조건	25	30	25/30
Judge 근거	27	30	29/30
Judge 판단	27	30	28/30
RAGAS Faithfulness(문항별 3회 평균의 평균)			0.775 (회차 차이 0.2 이상 9문항)
Hit@8 · Recall@8(지정 문서 기준, 참고)			1.000 · 0.902 (29문항)

회차	사실	조건	근거	판단	Faithfulness
e1	0.767	0.867	0.900	0.900	0.786
e2	0.700	0.800	0.900	0.900	0.782
e3	0.767	0.867	0.931	0.967	0.756

판정이 회차마다 갈린 항목은 12건이다: AS-ADD02 조건(1/0/0), AS-ADD03 사실(1/0/1), AS-ADD06 조건(0/0/1), AS-ADD06 판단(0/0/1), AS-ADD09 판단(0/0/1), AS-ADD10 조건(1/0/1), AS-ADD12 근거(0/0/not_applicable), AS-ADD13 사실(0/0/1), AS-ADD15 조건(0/1/0), AS-ADD18 사실(1/1/0), AS-ADD29 사실(1/0/1), AS-ADD29 조건(1/0/1). 다수결 값을 쓰되 사람 검수 전 잠정값이다.

Faithfulness 회차 차이가 큰 문항: AS-ADD03, AS-ADD07, AS-ADD10, AS-ADD11, AS-ADD12, AS-ADD19, AS-ADD25, AS-ADD27, AS-ADD29. 평균만으로는 이 변동이 드러나지 않는다.

상태와 기대 행동

상태 분포: abstained 1, answered 28, needs_clarification 1. 기대 행동과 다른 문항은 다음과 같다.

문항	기대 행동	실제 상태	허용 라벨 포함	Judge 판단(다수결)
AS-ADD06	answer	abstained	아니오	0 (2/3)
AS-ADD13	abstain	answered	예	1 (3/3)
AS-ADD15	abstain	answered	예	0 (3/3)
AS-ADD16	abstain	answered	예	1 (3/3)

5. 결과: 근거 확보(필수 사실 기준)

지표	v4 검수 반영	v4 평가기 판정	v1(참고)
필수 사실 충족률(최종 문맥, 매크로 평균)	0.911	0.899	0.922
필수 사실 충족률(후보 문맥)	0.922	0.911	0.945
후보 전체 근거 충족률	24/29 (82.8%)	23/29 (79.3%)	25/29 (86.2%)
최종 전체 근거 충족률	24/29 (82.8%)	23/29 (79.3%)	24/29 (82.8%)
최종 문맥 사실: 충족 / 검수 필요 / 미충족	85 / 4 / 4	84 / 6 / 3	93 / 5 / 3
사실 수(평가 대상)	93	93	101
기존 '지정 근거 전부 포함' 문항 수(참고)	15/29 (51.7%). 문서 Recall이 아니라 모든 지정 근거 묶음을 포함한 문항의 비율		

v4 평가기 판정이 v1보다 낮은 이유는 두 문항으로 설명된다. AS-ADD03은 개별 검토로 구체화한 문구가 검색되지 않은 규정을 요구해 검수 필요가 됐고, AS-ADD10은 이미 충족된 사실 하나가 삭제돼 비율이 내려갔다.

문항 분류

분류	문항 수	문항	의미
근거 충분·기존 Judge 통과	19	AS-ADD01, AS-ADD04, AS-ADD05, AS-ADD07, AS-ADD08, AS-ADD11, AS-ADD16, AS-ADD17, AS-ADD18, AS-ADD19, AS-ADD20, AS-ADD21, AS-ADD22, AS-ADD24, AS-ADD25, AS-ADD26, AS-ADD27, AS-ADD28, AS-ADD30	최종 문맥에 필수 사실이 모두 있고, 기존 답변 Judge 사실·조건 다수결이 1
근거 충분·기존 Judge 미통과	5	AS-ADD06, AS-ADD13, AS-ADD14, AS-ADD15, AS-ADD23	최종 근거는 충분하나 기존 답변 Judge 사실 또는 조건이 0(생성 오류 후보, 아래 메모)
검색·조회	3	AS-ADD02, AS-ADD09, AS-ADD10	후보 문맥에도 필수 사실의 근거가 없음
검수 필요(후보)	2	AS-ADD03, AS-ADD29	후보 단계 판정에 검수 필요가 남음

기존 Judge는 필수 사실 v4가 아니라 정답 파일의 원래 참고 정답으로 채점했다. 그래서 'Judge 미통과'를 곧바로 생성 오류로 단정하지 않고, 저장된 답변과 대조해 아래처럼 정리했다.

문항	근거 충분·기존 Judge 미통과 문항의 답변 대조 메모
AS-ADD06	기대 행동은 답변인데 보류(abstained)했다. 최종 근거가 충분하므로 답변 판단 오류 후보다.
AS-ADD13	기존 Judge 감점 사유(혼잡 공지가 자동 면제가 아님)는 v4 필수 사실이 아니다. 저장된 답변은 증빙 보완 대기, 추가 무료 2일 반영, 보관료 USD 140, 반납지연료·최종 합계 보류를 모두 담아 v4 기준으로는 충족에 가깝다.
AS-ADD14	기존 Judge 감점 사유(전체 9일 미명시)는 삭제된 요건이다. 금액과 무료·유료 날짜는 맞지만, 현행 F2의 '기본 3일 + 승인 추가 2일'을 답변이 명시하지 않아 별도 판단이 필요하다.
AS-ADD15	답변 첫 문장 '아니요'는 미반납 단정으로 읽히고, 본문은 미반납도 단정할 수 없다고 설명한다. 첫 문장과 본문의 일관성을 사람이 판단해야 한다.
AS-ADD23	실제 생성 오류다. 첫 산입일은 10월 27일인데 답변은 첫 유료일인 10월 30일을 첫 산입일로 썼다.

'지정 근거 전부 포함'을 통과하지 못했지만 최종 문맥이 모든 필수 사실을 뒷받침한 문항은 9개다. 7개(AS-ADD01, AS-ADD07, AS-ADD14, AS-ADD19, AS-ADD21, AS-ADD25, AS-ADD27)는 지정 페이지 일부로 충분했고, 2개(AS-ADD05, AS-ADD06)는 지정 목록 밖 페이지도 근거로 활용했다.

검색되지 않은 근거 쪽

문항	사실	필요한 원문	내용	현재 분류
AS-ADD02	F2	AS008 p8	변경 요청에 예약번호·변경 전후 내용을 적으라는 규정	검색·조회
AS-ADD09	F3·F4	AS009 p54	운송사에 봉인 정보 재전달, 기존·새 번호 함께 표시	검색·조회
AS-ADD10	F1	AS010 p1	기존 접수 경로로 정정한다는 규칙	검색·조회
AS-ADD03	F2	AS008 p9	취소 완료 회신 전에는 완료로 안내하지 않는다는 규정	검수 필요
AS-ADD29	F1	AS112 p25	실제 양하일을 독립적으로 확인해 주는 기록	검수 필요

각 쪽이 해당 문항의 후보·최종 문맥에 없음을 실행 기록으로 확인했다. AS-ADD03·29는 검색된 다른 원문이나 질문에 주어진 정보로 답할 수 있는지 사람이 판단해야 해 검수 필요로 남겼다.

6. 문항별 결과

근거 표시: O 충족, X 미충족, ? 검수 필요(필수 사실 v4, 검수 반영). *는 검수 판정을 반영한 문항. Judge는 사실·조건·근거·판단의 3회 다수결이며, 3회가 모두 같지 않을 때만 일치 수를 괄호로 붙였다. 경로는 첫 검색 경로(hybrid 하이브리드 검색, records DB 기록 조회).

문항	경로	상태	Judge	Faith.	사실	후보	최종	근거 분류	지정
AS-ADD01	hybrid	answered	1·1·1·1	0.80	3	OOO	OOO	근거 충분·기존 Judge 통과 · 지정 페이지 일부로 충분	0
AS-ADD02	hybrid	answered	1·0(2/3)·0·1	0.67	3	OX?	?X?	검색·조회 *	0
AS-ADD03	hybrid	answered	1(2/3)·1·1·1	0.70	2	O?	O?	검수 필요(후보)	0
AS-ADD04	hybrid	answered	1·1·1·1	0.83	2	OO	OO	근거 충분·기존 Judge 통과	1
AS-ADD05	hybrid	answered	1·1·1·1	0.84	2	OO	OO	근거 충분·기존 Judge 통과 · 지정 밖 페이지 활용	0
AS-ADD06	hybrid	abstained	1·0(2/3)·1·0(2/3)	0.68	3	OOO	OOO	근거 충분·기존 Judge 미통과 · 지정 밖 페이지 활용 *	0
AS-ADD07	hybrid	answered	1·1·1·1	0.65	2	OO	OO	근거 충분·기존 Judge 통과 · 지정 페이지 일부로 충분	0
AS-ADD08	hybrid	answered	1·1·1·1	0.86	2	OO	OO	근거 충분·기존 Judge 통과	1
AS-ADD09	hybrid	answered	0·1·1·0(2/3)	0.82	6	OOXXOO	OOXXOO	검색·조회	0
AS-ADD10	hybrid	answered	0·1(2/3)·1·1	0.63	2	XO	XO	검색·조회 *	0
AS-ADD11	hybrid	answered	1·1·1·1	0.83	2	OO	OO	근거 충분·기존 Judge 통과	1
AS-ADD12	hybrid	needs_clarification	0·0·0(2/3)·1	0.92	-	확인 질문(근거 평가 대상 아님)			-
AS-ADD13	hybrid	answered	0(2/3)·1·1·1	0.93	5	OOOOO	OOOOO	근거 충분·기존 Judge 미통과	1
AS-ADD14	hybrid	answered	0·1·1·1	0.83	3	OOO	OOO	근거 충분·기존 Judge 미통과 · 지정 페이지 일부로 충분	0
AS-ADD15	hybrid	answered	0·0(2/3)·1·0	0.86	3	OOO	OOO	근거 충분·기존 Judge 미통과	1
AS-ADD16	records	answered	1·1·1·1	0.89	4	OOOO	OOOO	근거 충분·기존 Judge 통과	1
AS-ADD17	hybrid	answered	1·1·1·1	0.93	3	OOO	OOO	근거 충분·기존 Judge 통과	1
AS-ADD18	records	answered	1(2/3)·1·1·1	0.90	3	OOO	OOO	근거 충분·기존 Judge 통과	1
AS-ADD19	hybrid	answered	1·1·1·1	0.79	5	OOOOO	OOOOO	근거 충분·기존 Judge 통과 · 지정 페이지 일부로 충분	0

AS-ADD20	records	answered	1·1·1·1	0.83	4	0000	0000	근거 충분·기존 Judge 통과	1
AS-ADD21	hybrid	answered	1·1·1·1	0.28	4	0000	0000	근거 충분·기존 Judge 통과 · 지정 페이지 일부로 충분	0
AS-ADD22	records	answered	1·1·1·1	0.95	3	000	000	근거 충분·기존 Judge 통과	1
AS-ADD23	hybrid	answered	0·0·0·1	0.92	4	0000	0000	근거 충분·기존 Judge 미통과	1
AS-ADD24	records	answered	1·1·1·1	0.88	3	000	000	근거 충분·기존 Judge 통과	1
AS-ADD25	hybrid	answered	1·1·1·1	0.63	4	0000	0000	근거 충분·기존 Judge 통과 · 지정 페이지 일부로 충분	0
AS-ADD26	records	answered	1·1·1·1	0.80	2	00	00	근거 충분·기존 Judge 통과	1
AS-ADD27	hybrid	answered	1·1·1·1	0.39	3	000	000	근거 충분·기존 Judge 통과 · 지정 페이지 일부로 충분	0
AS-ADD28	records	answered	1·1·1·1	0.88	4	0000	0000	근거 충분·기존 Judge 통과	1
AS-ADD29	hybrid	answered	1(2/3)·1(2/3)·1·1	0.48	4	?000	?000	검수 필요(후보)	0
AS-ADD30	records	answered	1·1·1·1	0.82	3	000	000	근거 충분·기존 Judge 통과	1

7. 운영 지표

항목	값
생성 시간	합계 757초, 문항 중앙값 22.7초, 최대 97.6초(순차 실행)
생성 토큰	입력 791,568 / 출력 18,694 (사용량 완전 기록 30/30)
모델 호출	92회(planner 62, answer 30), 실제 재시도 0
검색 경로	hybrid 22, records 8, SQL 호출 0
Judge 채점 토큰(회차별 입력/출력)	210,876/33,015 · 210,876/32,361 · 210,876/30,453. RAGAS 토큰은 기록되지 않음
근거 평가 호출	v1 58회, v2 28회, v3 2회, v4 2회. 호출·파싱 실패 0건(구조상 정상 응답이어도 인용 출처가 틀릴 수 있어 구절 확인과 검수를 따로 했다)
근거 평가 토큰(v4 판정 기준)	입력 408,848 / 출력 40,867

8. 한계와 후속 작업

확인된 한계

- 답변은 1회 생성 결과로, 같은 질문에 대한 생성 변동은 반영되지 않았다.
- 30문항 모두 SQL 호출이 0건이었다. 이 결과로는 SQL 조회 경로의 품질을 판단할 수 없다.

- 기존 답변 Judge는 원래 참고 정답 기준이라 필수 사실 v4와 기준이 다르다. 근거 평가와 답변 평가를 같은 필수 사실로 맞추려면 답변 채점을 다시 해야 한다.
- Judge v3의 조건 항목에는 서로 충돌하는 규칙 두 문장이 있어 반복 채점 변동의 원인이 된다. 평가 동안 기준을 고정했다.
- 필수 사실 v4 중 84개는 1차 검토 결과를 사람 확인 없이 반영했고, 삭제 9건은 개별 검토 없이 일괄 수락했다.
- 답변 생성·Judge·RAGAS·근거 평가·필수 사실 1차 검토가 모두 같은 제공사 모델이라 판정의 독립성에 한계가 있다.
- 공통 보고서의 재시도 수는 TableRAG의 planner 호출을 재시도로 센다(실제 0인데 62로 표시). RAGAS 토큰은 기록되지 않는다.
- 평가 후 검색 동작을 바꾸는 변경(#64 CPU 질의 임베딩 FP32 등)이 main에 병합됐다.

남은 작업

- 근거 평가의 남은 검수 필요 사실: AS-ADD02 F1(최종), AS-ADD02 F3(후보·최종), AS-ADD03 F2(후보·최종), AS-ADD29 F1(후보·최종). AS-ADD02 F3는 질문에 적용 연도·화물·장비 조건이 없어 조건부 마감을 인정할지 정해야 한다.
- Judge 판정이 갈린 12건과 'Judge 미통과' 중 AS-ADD14·15의 사람 검토
- 최종 채택 수치는 기준을 고정한 뒤 최신 main으로 다시 생성해 확인할지 팀 결정
- Langfuse 점수 게시 방식(최종 평가 세트) 결정

부록. 재현 정보

항목	값
실행 기록 runs.jsonl	`sha256:5303419256c6b52a6ec05b050b7478a737c776f1699f398286e892dd942ce273`
필수 사실 v4	`sha256:6f59fb71e9f1b6dad4df1cb38c00a9e0b66a147a4ae1e92c432b1da082186b1a`
검수 판정	experimental/Damsebi/fact-support/review-overrides.json (3건)
근거 평가 프롬프트	`sha256:da5c4bbad37d5c256a73105cc0e3c1bdc8951d0808732e6ff9d5193613741107`
Judge 프롬프트	`sha256:5c29900bc2f7c590358c8fc4c545a96a2ac5e8226d6d9406e35dec35de049cc4`
관련 PR	Somali-AI-Pirates/ADEN #54(HTTP 채점 연결), #55(평가 설정 정리), #62(additional 평가 결과), #63(근거 평가기·결과)
도구	app.evaluation.scripts.run_table_rag(run·grade), experimental/Damsebi/fix_compare.py(3회 다수결), fact_support.py(근거 평가), fact_support_report.py(집계)

참고 답변 원문과 원본 문서 구절은 이 보고서에 넣지 않았다.