ADVANCED SEARCH

Advanced 검색 실험 보고서

비용을 설명하는 데 필요한 기록을
한 번의 검색으로 얼마나 모을 수 있을까?

Advanced PDF 120개, 총 18,000쪽에서 챗봇이 답변에 참고할 페이지를 찾았다. **전체 근거 충족률**은 답변에 필요한 인용문을 지정된 출처에서 모두 가져온 질문의 비율이다.

HG는 비용 사건에 붙은 번호다

같은 HG 번호가 계약 약정, 현장 기록, 계약 대조·승인, 청구 명세, 수납·미결 기록에 반복된다. 이 다섯 쪽을 연결해 두면 하나의 비용 사건을 처음 약정부터 정산까지 살펴볼 수 있다. 머리말과 계약 번호를 대조해 2,730개 사건을 묶었다. [4]

명시 HG 조회

질문에 HG 번호가 하나 나오고 조회 목록에 등록된 번호라면, 연결해 둔 다섯 쪽을 찾는다.

> “HG2099-000001 건의 청구 금액과 수납 상태를 알려줘.”

간접 HG 조회

HG 번호가 없으면 화주·화물·장비 규격을 맞춰 본다. 세 단서가 한 사건에만 해당하고, 검색 후보 20쪽 안에 그 사건의 페이지가 있어야 다섯 쪽을 가져온다.

> “가람상사의 시범용 부품 40HC 건은 청구와 수납이 어떻게 됐어?”

두 질문은 설명용 예시다. 번호가 여럿이거나 질문이 해당 사건을 제외하면 원래 검색 순서를 쓴다. [4, 5]

최종 기준선 본문과 제목을 함께 보는 BM25 검색에 명시·간접 HG 조회를 더했다. 답변에는 복원한 원본 페이지를 보낸다. 비교에 사용한 증강 6,103문항에서 전체 근거 충족률이 **76.99%에서 99.98%로** 올랐다. 이 수치는 검색 결과로 모은 근거를 채점한 값이다. [4, 5, 8]

02 검색 비교 03 HG 결과 04 동료 비교 05 추가 실험 06 실행 방법

처음에는 검색 결과 3쪽을 비교했다

Snowflake-ko는 질문과 페이지 내용의 유사도를 비교한다. BM25는 질문에 나온 단어를 찾는다. Bigram은 한글을 두 글자씩, Kiwi는 형태소 단위로 나눈다. 두 검색의 순위를 합친 방법은 RRF다. 표의 비율은 단어 검색과 벡터 검색에 준 가중치다.

공식 평가 58문항	적중률@3	페이지 Recall@3	정밀도@3
Snowflake-ko 벡터 검색	67.24%	33.05%	27.01%
Bigram BM25	87.93%	49.57%	47.70%
Kiwi BM25	86.21%	59.05%	59.77%
Bigram + Snowflake-ko 7:3	91.38%	46.41%	43.10%
Kiwi + Snowflake-ko 6:4	87.93%	51.44%	48.28%
Kiwi + Snowflake-ko 6:4 → KURE 재정렬	**94.83%**	**60.20%**	**56.32%**

상위 3쪽 기준. 적중률은 근거를 한 쪽 이상 찾은 질문 비율, Recall은 필요한 쪽 중 찾은 비율, 정밀도는 가져온 쪽 중 정답 근거인 비율이다. [1]

상위 8개 결과에서는 어떤 방식이 앞섰나

문서 Recall@8은 상위 결과 8개에서 정답 근거가 있는 PDF를 얼마나 찾았는지 나타낸다. 공식 평가 60문항 중 58개와 별도로 마련한 평가 280개를 채점했다.

개인 실험 구성	추가 평가 280	공식 58
Kiwi + Snowflake-ko 6:4 → KURE 전체 재정렬	71.67%	78.45%
Bigram-ID BM25 단독	86.88%	87.07%
Bigram-ID BM25 → KURE 전체 재정렬	86.19%	78.74%
Bigram-ID BM25 → KURE 상위 3쪽 뒤에 BM25 순서	89.11%	86.64%
제목 보너스 단독	94.02%	88.07%
제목 보너스 + 명시·간접 HG	**94.20%**	**88.07%**

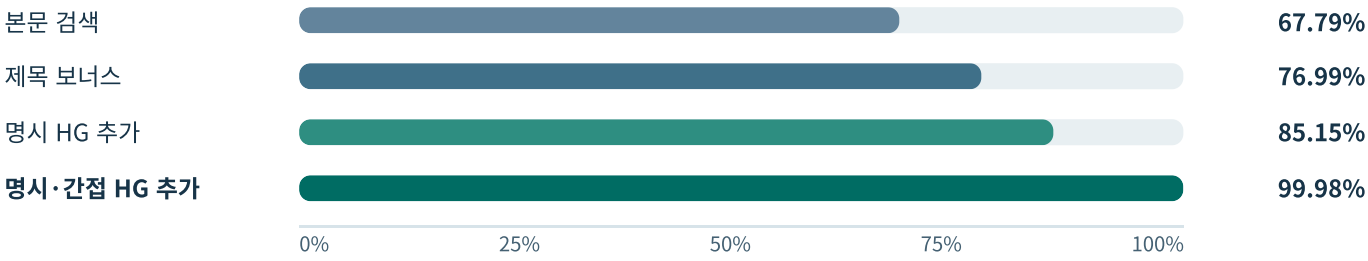
최종 구성은 추가 평가 32문항, 공식 평가 15문항에서 번호로 HG를 찾았다. 간접 조회를 적용한 문항은 0건이었다. [2, 8]

> 장비번호를 통째로 색인한 Bigram-ID는 벡터 검색을 더해도 이 평가에서 상위 후보 20쪽이 같았다. 이후 BM25를 중심으로 비교했다.
>
> 소제목·문단으로 쪼개 보내면 상위 3개 문맥은 짧아졌지만 들어간 인용문은 106개에서 94개로 줄었다. KURE 상위 3쪽에 2쪽을 더 보낸 답변 실험에서는 판단이 나아진 사례와 사실·인용이 나빠진 사례가 함께 나왔다. [1, 2]

사건을 연결하자 빠진 근거가 줄었다

원본의 근거를 바탕으로 6,500문항을 추가로 만들었다. 별도로 남겨 둔 평가 후보와 사건·기록 번호·출처가 겹치는 397개를 빼고 비교했다. 답변에 참고할 자료는 최대 8개, 총 4,000토큰으로 제한했다.

필수 근거를 모두 담은 질문의 비율



검색 방식	전체 6,103문항	HG 2,407문항	문서 Recall@8
본문 Bigram-ID + KURE 상위 3쪽	4,137건	441건 · 18.32%	90.11%
제목 보너스 단독	4,699건	1,004건 · 41.71%	95.48%
제목 보너스 + 명시 HG	5,197건	1,502건 · 62.40%	96.71%
제목 보너스 + 명시·간접 HG	**6,102건**	**2,407건 · 100%**	**100.00%**

HG 2,407문항은 6,103문항 중 비용 사건만 모은 것이다. 필수 사실마다 지정한 기본 인용문이나 검증한 대체 인용문을 확인했다. 6,500문항 전체에서는 최종 6,499건을 충족했다. [3–5]

번호로 찾자 498건이 더 충족됐다

비교에 쓴 명시 HG 질문 1,196개에서 모든 근거가 들어온 경우가 698개에서 1,196개로 늘었다.

단서로 찾자 905건이 더 충족됐다

간접 HG 질문 1,211개에서 근거를 모두 담은 질문이 306개에서 1,211개로 늘었다.

전체 6,500문항에서 다른 사건을 가져오거나, 이미 충족하던 질문에서 근거를 잃은 사례는 없었다. 다른 패턴도 같은 6,103문항에서 시험했다. 표의 일부 행만 보내면 7.23%, 역할별 순서를 바꾸거나 검색을 보태면 각각 67.84%, 적용 시점 주석을 붙이면 66.39%가 모든 근거를 충족했다. [3–5]

같은 번호를 묶는 두 방식

동료의 최종 v2 설정에는 언어 모델로 질문을 나누고 답변에 쓸 근거를 고르는 단계가 있다. 이 두 단계를 끈 상태에서 번호 연결을 켜고 끈 결과를 비교했다. 개인 결과도 같은 6,103문항으로 맞췄다. [9]

개인 설정

복원한 페이지를 통째로 검색한다. 본문 검색 결과에 제목 점수를 더하고 KURE nano로 순위를 매긴다. HG를 하나로 확인하면 연결해 둔 다섯 원본 쪽을 먼저 보낸다.

동료 설정

페이지 안에서 약 800자 기준으로 문단을 묶은 조각을 검색한다. E5-small 벡터 검색과 Bigram BM25를 합쳐 20개를 고르고 BGE로 재정렬한다. 질문에 번호가 없으면 1위 결과의 머리말에서 찾는다. 같은 번호를 공유하는 조각 가운데 PDF별로 점수가 가장 높은 것을 골라 최대 6개까지 앞에 올린다.

동료의 두 조건 모두 같은 PDF의 조각이 몰리면 감점했다(0.2). 번호 연결을 켜면 점수가 낮은 조각(BGE 0.05 미만)과 지나치게 자주 반복되는 번호를 걸렀다. 두 방식 모두 결과 8개·4,000토큰을 한도로 뒀다. 외부 API 호출은 0회였다. [5, 9]

설정	PDF Recall@8 6,103문항	쪽 Recall@8 6,103문항	전체 근거 충족 6,103문항	HG 근거 충족 2,407문항
동료 · 번호 연결 끔	69.21%	65.27%	3.44%	0.00%
동료 · 번호 연결 켬	91.33%	89.19%	34.56%	71.92%
개인 · 제목 보너스 단독	95.48%	95.40%	76.99%	41.71%
개인 · 제목 보너스 + HG	**100.00%**	**100.00%**	**99.98%**	**100.00%**

쪽 Recall은 PDF 안에서 필요한 쪽을 찾은 비율이다. 맨 오른쪽 열은 HG 질문만 놓고 필수 근거를 모두 담았는지 센다. [5, 9]

페이지를 찾고도 인용문이 빠진 경우

동료 방식에서 번호 연결을 켜자 비용 사건 2,407문항 중 **1,731개**에 모든 근거가 들어왔다. 제목 보너스만 쓰면 1,004개였다. 사건 번호로 기록을 묶는 효과가 여기서 드러났다.

반면 한 쪽만 필요한 업무 자료집 3,572문항에서는 동료 방식이 **97.70%**의 정답 페이지를 찾았고, 인용문이 모두 들어온 질문은 **209개**였다. 채점에서는 지정한 쪽에서 인용문이 같은 글자로 이어져야 일치로 셌다. 동료가 PDF에서 뽑아낸 텍스트에는 검색 전부터 채점용 인용문과 같은 문자열을 찾기 어려운 경우가 많았다. 그래서 두 사람의 점수 차이에는 검색 순위와 PDF 추출 방식이 함께 반영됐다. [9]

> **별도 340문항 평가** 문서 Recall@8은 동료 번호 연결이 추가 평가 **97.86%**·공식 평가 **96.84%**, 개인 최종 설정이 **94.20%**·**88.07%**였다. 이 묶음에서는 동료 설정이 필요한 PDF를 더 자주 찾았다. [2, 8]

마지막으로 비교한 세 가지

HG 조회로 근거를 모은 다음, 보낼 텍스트를 줄이거나 다른 문서까지 번호로 찾는 방법을 시험했다. 비용 계산은 따로 확인했다.

01 페이지 전체와 필요한 줄만 발췌한 결과

같은 HG 검색 결과에서 겹침 없는 비용 사건 2,407문항의 근거를 모두 담았다. 표의 머리글·관련 행·조건만 발췌하니 다섯 기록은 짧아졌다. 빈자리에 다음 검색 결과가 더 들어와 실제로 보낸 텍스트는 길어졌다. [6]

HG 2,407문항	복원 원본	출처 발췌
전체 근거 충족률	100%	100%
답변에 보낸 텍스트의 평균 길이	3,702토큰	3,852토큰
보낸 페이지 수의 평균	7.44쪽	7.85쪽

02 HA 터미널 사례와 업무 자료집도 번호로 찾기

터미널 198문항과 업무 자료집 1,399문항, 총 1,597문항에서 번호로 정답 근거 쪽을 찾았다. 기존 검색도 이 질문들의 근거를 모두 담고 있었다. 번호 조회를 더해도 새로 충족하거나 근거를 잃은 질문은 없었다. [7]

동일한 6,103문항	검색 + HG	HA·자료집 조회 추가
모든 필수 근거를 담은 질문	6,102건 · 99.98%	6,102건 · 99.98%
쪽 Recall@8	100.00%	100.00%
답변에 보낸 텍스트의 평균 길이	3,711토큰	3,711토큰

03 원문에 적힌 비용 다시 계산하기

HA 비용 396건 가운데 계산 조건을 확인한 254건은 모두 원문에 적힌 금액과 일치했다. HA 142건은 조정·개정·증빙을 더 확인해야 했고, HG 비용 5,460건은 계약 단가의 통화를 확인할 수 없어 보류했다. [7]

제목 보너스 검색과 HG 조회를 유지한다. 복원 페이지는 같은 근거를 더 짧은 텍스트로 전달했고, HA·자료집 번호를 따로 찾는 방법은 이번 비교에서 추가 근거를 확보하지 못했다.

실행 방법과 결과를 읽는 기준

현재 기본값은 복원한 페이지에서 검색한 뒤 HG 조회를 적용한다.

01 후보 찾기
제목 보너스
본문 검색의 상위 80쪽에 제목 점수를 더해 20쪽을 고른다.

›

02 순서 바꾸기
KURE nano
KURE 상위 3쪽을 먼저 놓고, 나머지는 원래 순서를 쓴다.

›

03 텍스트 보내기
확인된 HG 우선
같은 사건 5쪽을 앞에 넣고 최대 8쪽·4,000토큰을 보낸다.

```
HF_HUB_OFFLINE=1 TRANSFORMERS_OFFLINE=1 \
  uv run --no-sync python -m experimental.u_10o0o.advanced_search
```

복원 페이지, Advanced 정제본, HG 사건 인덱스, 로컬 KURE nano와 CUDA가 필요하다. 기본 실행은 공식 60문항과 별도 평가 280문항을 사용한다. 제목 보너스 단독도 보려면 **--compare**를 붙인다. [8]

> 증강 질문은 원문에 있는 번호나 단서를 사용해 만들었다. 단서를 생략하거나 다른 이름으로 부르는 실사용 질문과 실제 답변 품질은 별도 평가가 필요하다. HA·자료집 번호 조회는 검색 뒤에 추가했다. 번호 조회가 검색을 대신하는 방식의 속도는 별도 평가 항목이다.

실험별 기록

아래 경로는 experimental/u_10o0o/records/를 기준으로 적었다.

[1] 초기 검색·리랭킹과 문맥 비교
`retrieval_evaluations/advanced-baselines.md`
`advanced-reranking-cutoffs-20261108/`
`advanced-structure-chunking-20261108-215143-955031/`
`advanced-context-expansion-20261108-223239-683500/`

[2] 검색 변수를 바꾼 340문항 실험
`advanced-factor-ablation-20261108/`

[3] 제목 보너스와 다른 검색 패턴
`advanced-industry-patterns-20261108/`

[4] HG 사건 연결과 명시 조회
`advanced-curation/hg-case-sources-20261109/`
`advanced-curation/hg-explicit-lookup-20261109/`

[5] 간접 HG 조회
`advanced-curation/hg-indirect-lookup-20261109/`

[6] 역할별 정규화와 출처 발췌
`advanced-curation/hg-role-facts-20261109/`
`advanced-curation/hg-role-context-20261109/`

[7] 양식 조회 확장과 비용 재계산
`advanced-curation/format-extension-20261109/`
`advanced-curation/charge-audit-20261109/`

[8] 기본 실행 및 최종 결정
`decisions.md`

[9] 동료 설정과 PDF 인용문 검증
`advanced-industry-patterns-20261108/peer-comparison/`