해운 문서 기반 질의응답

ADEN

해운 문서를 바탕으로 업무 질문에 답하고 원문 출처를 제공하는 서비스

소말리아 AI 해적단

최재선
팀 리드 · RAG·서버·배포

이용석
검색 개선 · 프롬프트·통합

이정수
평가·추적·품질 검증

최선영
답변 생성·검증·API

발표 순서

01 문제와 전체 흐름

02 데이터 준비

03 검색과 TableRAG

04 멀티턴과 답변 생성

05 실행 추적과 평가

06 서비스 시연과 마무리

01

문제와 전체 흐름

업무 질문 · 자료 특성 · 전체 처리 구조

01 **문제와 전체 흐름**

02 데이터 준비

03 검색과 TableRAG

04 멀티턴과 답변 생성

05 실행 추적과 평가

06 서비스 시연과 마무리

업무 사례: 청구·수납·적용 규정

**“HG2030-00123의 청구액과 수납 상태를 확인하고,
적용 규정도 알려줘.”**

청구서 · 예시 12쪽

청구액 120,000 KRW
대상 HG2030-00123

수납대장 · 예시 13쪽

수납 상태: 미결
청구액과 별도로 확인

업무 규정 · 예시 40쪽

청구와 수납은 구분
대상·기준일도 확인

필수 근거: 청구액 + 수납 상태 + 적용 규정

구조 설명용 가상 사건 · 코드·값·문서·페이지는 실제 실행과 구분

전체 구조: 질문에서 답변까지

사전 준비 PDF → 기록·표 SQLite + 페이지·표 검색 색인

① 대화 해석
대상·요청 해석

→

② 근거 확보
DB·문서·표 조회

→

③ 답변 작성
원문과 SQL로 작성

→

④ 확정·전달
검증 → 저장 → 화면

저장 후 별도 평가: Ragas · Judge → Langfuse 점수

실행 기록: 채팅 중 저장 | Ragas·Judge: 저장된 답변으로 별도 평가

Advanced 자료: 기록·코드·규정

HG · 사건별 업무 기록

- 약정·현장·승인·청구·수납
- 사건별 단계 연결

HA · 계약·증빙 자료

- 계약·장비·증빙·정산
- 코드·적용 범위 연결

IS · 업무 안내·기록

- 규정·절차·처리 기록
- 본문 설명 + 표

원문 페이지	표 검색 문서	전체 검색 단위	계산용 물리 표
18,000쪽	3,750개	21,750개	21,126개

현재 번들 기준 · 표 검색 문서 = 검색용 텍스트 묶음 / 물리 표 = SQL 조회 단위

02

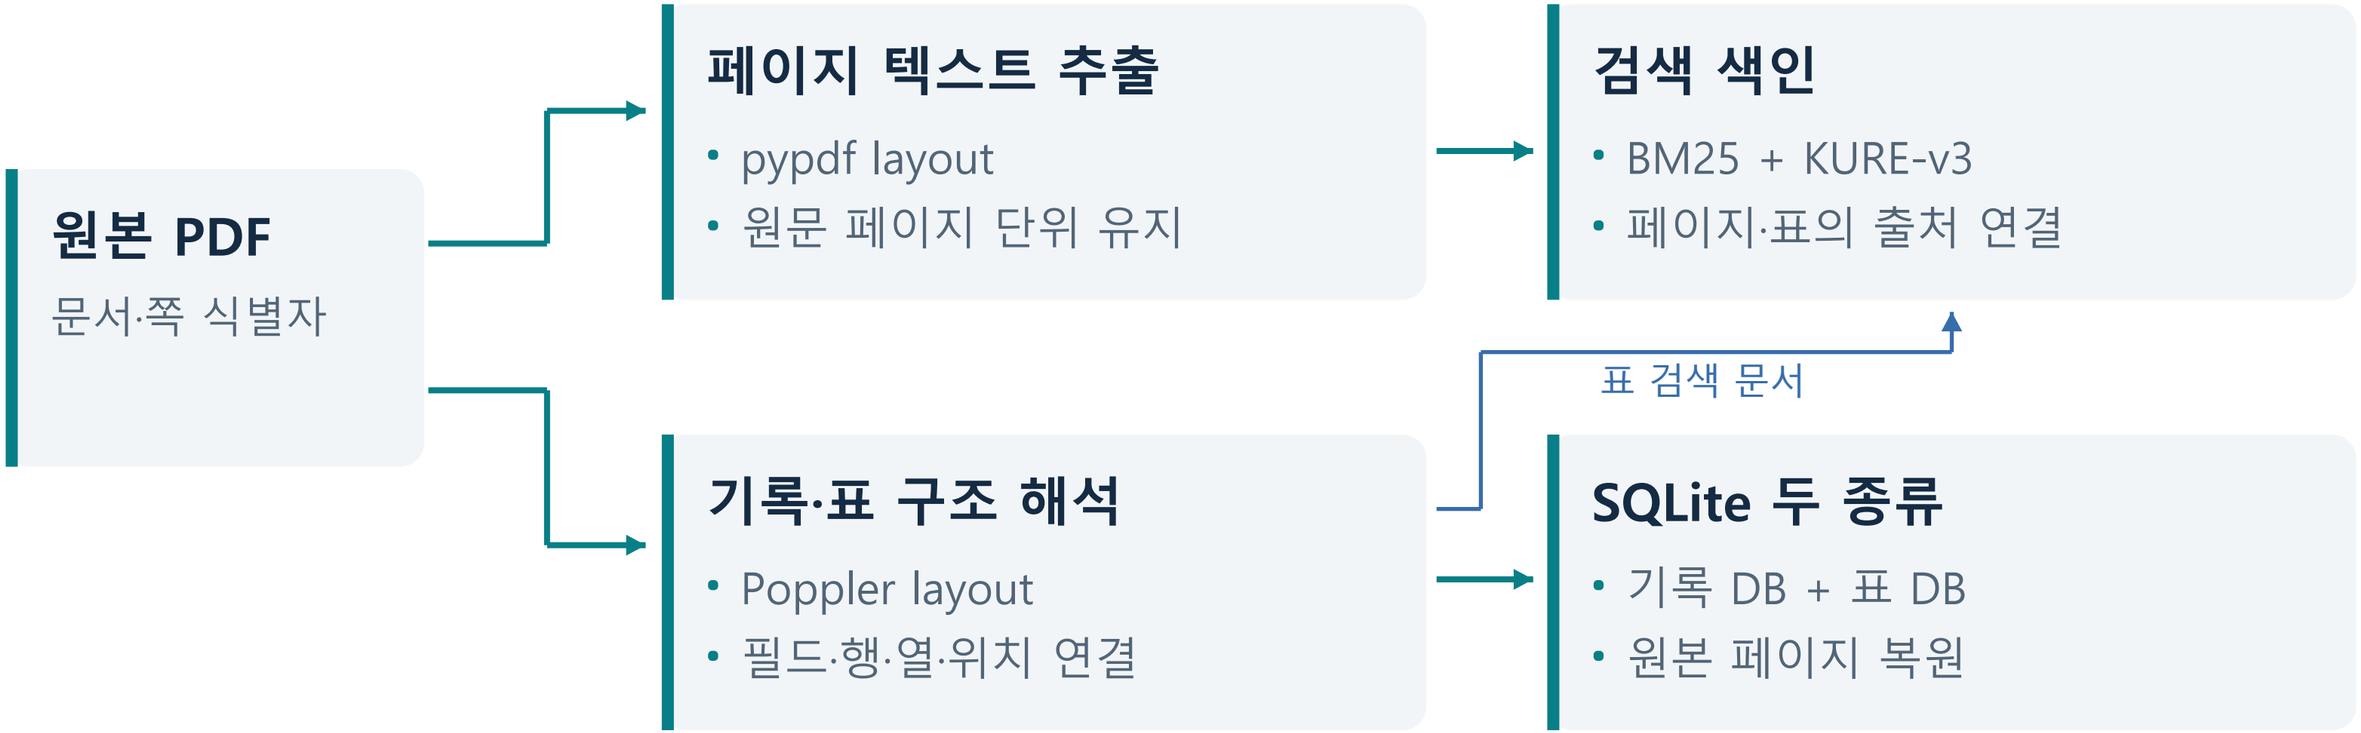
데이터 준비

원본 추출 · 기록 구조화 · 표·출처 저장

01 문제와 전체 흐름
02 데이터 준비
03 검색과 TableRAG
04 멀티턴과 답변 생성
05 실행 추적과 평가
06 서비스 시연과 마무리

PDF 전처리: 검색과 구조화

검색: 내용 탐색 | 구조화: 값·관계 조회와 표 계산



보존 기준: 원문 값·순서·출처

사전 데이터 준비

필드 추출: 값·의미·출처 보존

HG2030-00123 · 날짜 종류·통화·상태를 원문과 함께 보존

가상 원문 발췌

예약 HG2030-00123

예정 반출 2030-11-10

실제 반출 2030-11-12

청구액 120,000 KRW

수납 상태 미결

읽은 값	보존할 의미
2030-11-10 / 11-12	예정일 / 실제일
120000 · KRW	청구액 · 통화
미결	수납 상태 · 0원이 아님
문서 · 쪽 · 행·열	각 값이 나온 원본 위치

저장 위치: 기록 속성 / 표 셀 / 원문 페이지

구조 설명용 예시 · 날짜 종류·통화·미결 상태 유지

기록 DB: 코드와 원본 연결

대상·역할·원문 연결 관리 | 금액·상태는 연결된 원문·표에서 확인

코드 · keys

HG2030-00123
완전 예약번호

대상 · entities

HG 사건 A
원문으로 확인한 대상

청구 원문 · invoice

예시 청구서 12쪽
청구액 120,000 KRW

속성 · attributes

실제 반출일: 2030-11-12
연결 정보: 값의 원문 출처

sources
대상 ↔ 역할 ↔ 원문

수납 원문 · receipt

예시 수납대장 13쪽
수납 상태: 미결

구조 설명용 예시 · attributes가 모든 금액을 저장하지는 않음 · 원문·표 조회와 병행

대상 식별: 코드 정규화와 관계 확인

입력 코드
대소문자·구분자

→

표기 정규화
동일한 코드 표기

→

키·출처 조회
원문에 확인된 관계

→

대상 확정
유일할 때만 DB 우선

완전 코드 → 대상 → 기록

- HG2030-00123 → 사건 A
- 요청 필드·역할로 원문 조회

공유 규격·부분 번호의 한계

- 20GP: 여러 대상이 공유
- 대상 미확정 → 문서 검색

구조 설명용 예시 · 코드 연결 조건: 원문의 명시 관계 확인 · 단순 공출현만으로 연결 금지

표 DB: 원문 셀과 계산용 값

HG2030-00123 · 청구액 120,000 KRW · 구조 설명용 예시

원문 표 · 설명용 청구서 12쪽

예약번호	항목	청구액
HG2030-00123	보관료	120,000 KRW



원문 열은 그대로	계산에 쓸 보조 열	행의 원본 연결
c0 = HG2030-00123 c1 = 보관료 c2 = 120,000 KRW	c2_value = 120000 c2_unit = KRW c2_state = reported	해당 행의 ID → 청구서 12쪽 → 원문 행 범위

구조 설명용 예시 · 미결·공란 ≠ 0 · 원문에서 단일 값으로 확인된 셀만 계산용 값 생성

표 검색과 읽기 전용 SQL

표 카탈로그 검색
제목·열·예시 값

→

열 구조 확인
확인한 표 ID·열

→

읽기 전용 SQL
조건·단위·집계 범위

→

값 + 원문 출처
행별 원문으로 연결

FTS5 · 표 카탈로그

- 색인: 제목·열·예시 값
- 출력: 관련 표·스키마

BM25 · 문서 키워드 검색

- 대상: 페이지·표 검색 문서
- 벡터와 결합 → 문서 후보

SQL 제한: 확인한 표만 조회 · 읽기 전용 · Decimal 연산 · 결과 크기·시간 제한

03

검색과 TableRAG

하이브리드 검색 · 리랭킹 · 도구 선택과 반복

01 문제와 전체 흐름
02 데이터 준비
03 **검색과 TableRAG**
04 멀티턴과 답변 생성
05 실행 추적과 평가
06 서비스 시연과 마무리

BM25: bigram과 완전 코드 보존

한글: 겹침 bigram | 영문·숫자: 단어 토큰 | 완전 코드: 별도 보존

**HG2030-00123의 청구액과 수납 상태를 확인하고,
적용 규정도 알려줘**

hg2030	00123	청구	구액	수납	상태	hg2030-00123

실제 토큰 중 핵심만 표시 · “청구액과” → 청구 / 구액 / 액과

후보 A · 같은 사건의 청구서

HG2030-00123 / 청구액
완전 코드와 요청 항목이 함께 일치

후보 B · 다른 사건의 청구서

HG2030-00456 / 청구액
청구 표현은 같아도 완전 코드는 다름

희소성·빈도·길이로 점수 계산 → 본문 후보 안에서 제목 일치 점수 × 0.25 반영

토큰: 실제 함수 확인 / 후보: 설명용 · 여러 토큰의 종합 점수 사용 · 코드 일치만으로 순위 보장 불가

KURE-v3: 의미 기반 후보 검색

KURE-v3 · 2,048차원 임베딩 · Qdrant exact 코사인 검색

대상을 풀어 쓴 질문

"HG2030-00123은 납부됐어?"
"이 사건의 수납 상태는?"

관련 문서의 표현

"청구와 수납은 별도로 확인한다"
"입금 확인 전에는 수납 미결"

의미 벡터 비교

- 질문: 매 요청 생성
- 문서: 사전 생성

Top 50

의미가 가까운
문서 후보

가상 문서·표현 예시 · 의미 유사도 ≠ 대상·상태·규정 적용의 정확성

RRF: BM25·벡터 순위 결합

BM25 Top 50 + 벡터 Top 50 | 가중치 5:5 · 상수 60

후보 · 설명용	BM25 순위	벡터 순위	합친 점수
A · 청구 기록	1	10	0.01534
B · 수납 기록	3	3	0.01587
C · 적용 규정	2	Top 50 밖	0.00806

합친 순서 B → A → C

페이지 중복 제거
→ 리랭커 입력 최대 20쪽

설명용 순위·계산값 · 5:5 RRF, 상수 60 · 한쪽 Top 50 밖의 기여는 0 · Cormack et al., 2009

KURE nano: 질문·후보 재비교

질문·후보 원문을 함께 입력 | 문서 검색에만 적용

질문: 청구액·수납 상태·적용 규정을 확인해줘

RRF 후보 순서

1 B · 수납 기록
2 A · 청구 기록
3 C · 적용 규정

→

질문 + 후보를 함께 입력

질문 ↔ B 원문
질문 ↔ A 원문
질문 ↔ C 원문

→

다시 정렬 · 예시

1 A · 청구 기록
2 C · 적용 규정
3 B · 수납 기록

설명용 순위 · 실측값 아님 · 검색 호출당 리랭킹 1회 → 근거 구성에서 최종 최대 8쪽 선택

TableRAG: 사전 구축과 질문 처리

참고: TableRAG의 문서·SQL 연결 | ADEN 확장: 코드 기반 기록 조회

사전 준비

원본 PDF

문서·표·출처

페이지·표 검색 색인

기록 조회·표 계산 SQLite

질문에 필요한 저장소 조회

질문 처리

초기 근거

코드 확정: DB 우선
그 외: 문서 검색

계획·도구 선택

규정 검색 · 원문 읽기
기록 조회 · SQL

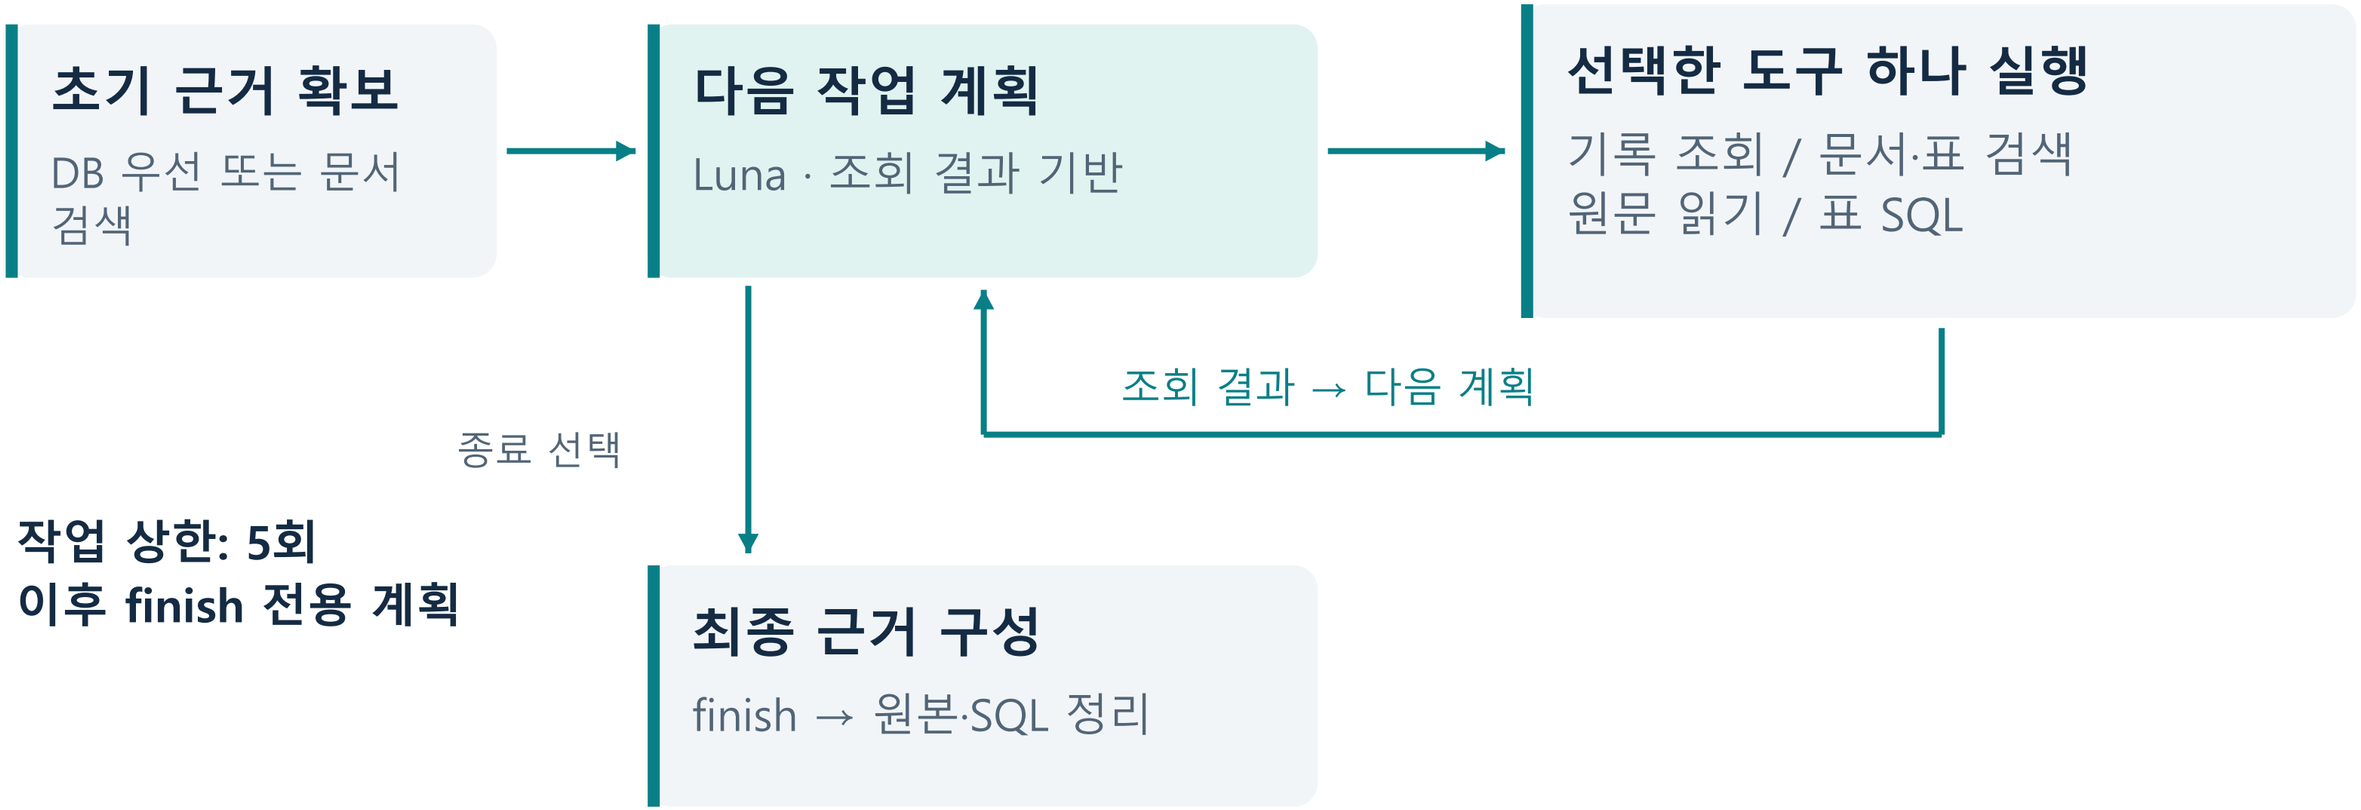
최종 원문 + 답변

원문 출처 보존
별도 답변 모델 호출

TableRAG · Yu et al., EMNLP 2025, Fig. 2 참고 · ADEN 확장 구조 · 논문 전체 재현은 아님

LangChain·LangGraph 실행 구조

한 단계 한 도구 · 조회 결과에 따라 재계획 또는 종료



LangGraph StateGraph · 요청별 State와 Runtime context 분리 · 답변 생성은 그래프 종료 후 서비스에서 실행

도구별 입력과 반환 결과

도구	사용 조건	실제 반환 내용
lookup_records	코드·대상별 값·기록 조회	HG·HA·IS 속성 + 원본 출처
search_evidence	규정·문서·표 발견	문서 후보 / 표 카탈로그·스키마
read_sources	발견한 페이지의 전체 원문 확인	이미 발견한 출처의 원문
query_tables	표 필터·합계·집계	읽기 전용 SQL 결과 + 행 출처
finish	답변 가능 범위 결정·종료	충분 / 추가 확인 / 근거 부족 + 선택 출처

BM25·벡터·KURE 적용: 문서 검색만 · 별도 경로: FTS5 표 검색 / 기록 조회 / 원문 읽기 / SQL

실행 사례: 규정 검색·원문 확인

저장 질문 발췌: “기본표의 무료일수, 계약에서 봐준 날, 깎기로 한 돈을 어떤 순서로 적용해?”

실제 실행 순서	요청·반환된 근거	연결되는 정보
초기 하이브리드 검색	원래 질문으로 문서 후보 확보	무료일수·감액 관련 단서
search_evidence · 1회	무료기간·감액 순서 재검색	AS017의 비용 계산 규정
search_evidence · 2회	거래처 한정 조건·계약 범위 검색	AS020 19쪽 등 계약 적용 자료
read_sources	AS020 19쪽 + AS017 37쪽 읽기	계약 우선 조건 + 계산 원칙
finish → 근거 구성	핵심 출처 2개 선택 · sufficient	보충 후 최종 8쪽으로 답변

과거 저장 실행의 실제 도구 순서 · Luna medium / 후보 20 · 최종 8쪽 · 8,000토큰 · 최신 프롬프트 성능 검증과 구분

SQL 사례: 행 수 계산과 출처 연결

IS01-010-01 · COUNT(*) 실행을 명시한 기능 확인 질문

조회에서 확인한 표

인계번호 · 대상 · 요청 업무
담당 · 연락 창구

query_tables

SELECT COUNT(*)
AS row_count
FROM 확인한 표

SQL 반환 결과

row_count = 7
원본: AS007 10쪽

저장된 실제 답변

“표의 스키마는 인계번호, 대상, 요청 업무, 담당, 연락 창구이며,
COUNT(*) AS row_count 결과 전체 7행입니다. [AS007:p0010]”

최종 근거: 원문 복원과 예산 제한

최종 문맥: 답변 모델에 전달할 원문 페이지와 SQL 결과

청구서 · 예시 12쪽

120,000 KRW
대상 HG2030-00123

수납대장 · 예시 13쪽

미결 상태
청구와 다른 기록

규정 · 예시 40쪽

청구와 수납 구분
대상·시점 확인

원본 복원 → 페이지 중복 제거 → 길이 확인 → 최종 근거

최대 8쪽 · SQL 결과 포함 8,000토큰

핵심 출처 유실 → 근거 부족 처리·답변 범위 제한

구조 설명용 예시 · 검색 후보 최대 20쪽 / 답변 최종 근거 최대 8쪽

04

멀티턴과 답변 생성

대상 복원 · 프롬프트 · 답변 상태와 검증

01 문제와 전체 흐름
02 데이터 준비
03 검색과 TableRAG
04 멀티턴과 답변 생성
05 실행 추적과 평가
06 서비스 시연과 마무리

멀티턴: 대상 복원과 근거 재조회

입력: 브라우저의 완료된 Q/A 최대 8턴 | 서버 영구 기억 없음

현재 질문 + 이력
완료된 턴만 전달

→

최근 2턴 해석
대상·조건·참조 확인

→

필요 시 1회 확장
전달된 최대 8턴 안에서

독립 질문

- 현재 질문으로 검색
- 이력에서 대상 보충 불필요

대상 확정

- 선택 대화로 질문 복원
- 새 원문 조회

대상 모호

- 조회 생략
- 최소 식별 조건 되묻기

이력 없음: 해석 모델 생략 · 이전 답변의 금액·판정·인용: 사실 근거로 재사용 금지

멀티턴 사례: “그 건”의 수납 확인

앞선 대화: HG2030-00123의 청구액·수납 상태·적용 규정 확인

사용자 후속 질문: “그 건은 납부됐어?”

① 대화 해석 지침

“그 건” → HG2030-00123
복원 질문:
“이 사건의 수납 상태는?”

② 검색 계획 지침

요청: 수납 확인
조회: receipt 원문
근거: 수납 미결

③ 최종 답변 지침

청구와 수납을 구분
“수납 기록에는 미결로
기재돼 있습니다.”

가상 예상 응답 · 이전 값·판정 복사 금지 · 대상 미확정: 추가 확인

답변 입력: 대화와 사실 근거 분리

대화: 대상·조건 해석 | 사실: 이번 요청의 최종 원문·SQL

현재 질문 + 선택한 대화

"그 건은 납부됐어?"
대상: HG2030-00123

새로 조회한 원문

수납대장 13쪽: 미결
청구서 12쪽: 120,000 KRW

최종 답변 모델 · Luna

"수납 기록에는 미결로 기재돼 있습니다.
납부가 완료됐는지는 이 기록으로
확인되지 않습니다. [수납 13쪽]"

질문·원문·SQL·종료 상태 → answer / reason / citations / status

가상 예상 답변·출처 표기 · 이전 대화·검색 요약은 사실 근거에서 제외

업무 판단: 날짜·효력·상태 구분

자료에 적힌 사실 · 예시	피해야 할 답변	근거에 맞는 답변
예정 11/10 · 실제 11/12	“11/10에 반출됐습니다.”	“실제 반출일은 11/12입니다.”
11/12 승인 · 질문 기준일 11/11	“11/11에도 승인 상태입니다.”	“기준일 이후 승인입니다.”
한 비용 항목만 정정	“계약 조건 전체가 바뀌었습니다.”	“보관료만 정정됐고, 다른 계약 조건은 유지됩니다.”
청구 12만 원 · 수납 미결	“12만 원을 납부했습니다.”	“청구액은 12만 원, 수납은 미결입니다.”

구조 설명용 예시 · 기재액 조회 ≠ 독립 검산 · 날짜·요율·승인 조건의 추정·역산 금지

답변 상태: 조건과 응답 방식

상태	판단 조건	응답 방식
답변 가능	요청을 뒷받침하는 근거 확보 예: 실제 반출일 확인	결론 + 문장별 출처
추가 확인	대상·기준일·의도 모호 예: 두 사건 중 대상 미확정	최소 식별 정보 요청
부분 답변·보류	일부 근거만 확보 예: 기재액 확인·검산 조건 부족	확인 항목 답변 + 미확인 범위 보류

- reason: 상태 선택의 업무상 이유·미확인 범위 · 내부 추론 제외
- 근거 미발견 ≠ 사실 부재 · 검색 단계의 근거 부족 상태 유지

검증: 출력 계약과 의미 정확성

구분	검사 항목	한계
코드의 출력 검사	JSON 형식 · 상태 일치 · reason 인용 ID가 최종 출처에 있는지	주장에 대한 실제 근거 지지 여부는 별도 의미 검토 필요
프롬프트의 업무 판단	대상 · 효력 시점 · 상태 · 단위 부분 정정 · 검산 조건	모델 해석 오류 가능
저장 후 평가·검토	주장별 근거 지지 · 참고답 충족 누락·오해·불필요한 단정	평가 모델·채점 기준도 검토 대상

출처 ID 유효성 ≠ 사실 정확성 · 실행 기록과 사후 평가로 확인

스트리밍: 임시 출력과 응답 확정

검색·계획 진행
진행 상태 전달

→

답변 조각 표시
아직 임시 내용

→

검증·실행 저장
상태·인용·기록 확인

→

최종 응답 확정
답변·출처 카드 제공

실패 처리

- 모델·검증·저장 오류 전달
- 실패 시 final 응답 없음

원문 연결과 표시 범위

- 문서 ID + 쪽 → PDF
- 해석·도구 인자·내부 추론 비노출

스트리밍 범위: 답변 생성 중 임시 출력 · 검색·계획 대기는 별도 · 검증·저장 후 final 확정

05

실행 추적과 평가

요청 추적 · 저장 결과 평가 · 단계별 실패 분석

01 문제와 전체 흐름
02 데이터 준비
03 검색과 TableRAG
04 멀티턴과 답변 생성
05 **실행 추적과 평가**
06 서비스 시연과 마무리

Langfuse: 요청 단위 실행 추적

저장된 규정 질문의 실행 순서를 현재 추적 구조에 대응

rag-query · 요청 한 건

- 초기 문서 검색
- 계획 ↔ 추가 검색 2회
- 계획 ↔ 원문 읽기 → finish
- retrieval / final-context · 최종 근거
- answer-N · 최종 답변·사용량

공식 CallbackHandler

- LangChain·LangGraph 연동
- 모델·도구를 동일 trace로 연결
- 요청별 독립 기록

로컬 실행 기록

- 질문·원문·SQL·답변
- 사용량·출처·trace ID
- 평가에 저장 결과 재사용

과거 실행 → 현재 추적 구조 대응 도식 · 원격 화면 캡처 아님 · 과거 trace 원격 저장 미재검증

평가 체계: 충실도와 업무 정확성

생성: Luna medium | 채점: Luna max · 저장된 답변·최종 근거 재사용

저장된 결과
답변·원문·SQL

→

평가 입력 구성
참고답은 채점에만

→

지표별 채점
Ragas + Judge

→

trace에 점수 연결
점수·판정 근거 확인

Ragas Faithfulness · 충실도

- advanced · 사실 주장별 근거 지지율
- 근거: 실제 최종 원문·SQL
- 질문 완수·정답 정확도와 구분

Judge · 업무 답변 평가

- 평가 축: 사실·조건·근거·판단
- 기준: 참고답·업무 조건
- 확인: 요청 누락·잘못된 단정

채팅 후 별도 채점 · 평가 불가를 0점으로 대체하지 않음 · 완료 유형 결과 수록

실패 분석: 필요한 사실의 전달 과정

설명용 사례 · 질문에 필요한 사실: “수납 상태는 미결”

검색·DB 조회
사실의 근거 발견

→

답변에 넣을 근거
필요한 사실 보존

→

최종 답변
정확하게 전달

확인 지점	관찰되는 상황	구분할 문제
근거 확보	미결 상태를 뒷받침하는 기록을 찾지 못함	해석·조회·검색 누락
근거 선택	기록은 찾았지만 답변 입력에 남지 않음	최종 근거 유실
답변 작성	미결을 “납부 완료”로 설명하거나 생략	답변 오해·누락

같은 사실을 지지하는 다른 출처도 인정 · 원인 불명확·평가 불가는 별도 검토

최종 벤치마크: 채점 완료와 검토 범위

280문항 답변 생성·자동 채점 완료 · 실행 오류 0건

평가 묶음	문항 수	현재 반영 범위
Development / Additional	30 + 30	공식 60문항: AI 검토 보정 반영
카테고리	180	상황별 1–8번 + 업무 규정 · 보정 대기
Custom	40	단일·복합 질문 · 보정 대기
전체	280	자동 채점 완료 · 전체 보정 종합은 미확정

이번 결과: 공식 60문항 · 동일한 제품 답변의 채점 판정 보정

문항별 질문·답변·최종 근거 고정 · 새 답변 생성 및 평가 모델 호출 없음

공식 평가: 오류 의심 34문항 선별 검토

Development 30 + Additional 30 · AI 자체 검토 · 사람 검수 아님

원 자동 채점
60문항 완료

→

오류 의심 검토
34문항 원문·답변 대조

→

보정 결과
근거·답변·충실도·Judge

원점수 유지 26문항

- 적용된 지표가 모두 만점
- 사용자 요청으로 의미 검토 생략
- 전체 60문항 전수 검수로 표현하지 않음

보정 원칙

- 출처 형식과 의미 판정 오류 구분
- 상향·하향·판단 보류 모두 허용
- 원점수와 문항별 보정 근거 별도 보존

선별 검토에는 선택 편향이 남음 · 점수 변화는 제품 개선이나 새 독립 벤치 성능이 아님

공식 60문항: AI 검토 보정 결과

최종 근거와 답변의 필수 사실 · 중복 주장을 정리한 근거 충실도

필수 사실의 근거 확보

96.5%

55/57 문항 · 불가 3

필수 사실의 답변 정확성

90.0%

54/60 문항 · 불가 0

AI 검토 보정 충실도

0.981

평균 · 평가 60문항 · 불가 0

지표	측정 내용
근거 확보	최종 원문·SQL이 질문에 필요한 사실을 모두 지지
답변 정확성	질문이 요구한 사실을 빠짐없이 정확하게 전달
보정 충실도	문서 기반 주장의 지지 비율 · 사용자 조건·예시·중복 구분

지표마다 분모가 다름 · 보정 충실도는 원 Ragas advanced와 구분 · 전체 정답률이 아님

보정 전후: 평가 기준과 판정의 변화

동일한 질문·제품 답변·최종 근거를 사용 · 비율 차이를 검색 개선으로 해석하지 않음

지표	원 자동 채점	AI 검토 보정	평가 불가
필수 사실 근거 충족	47/50	55/57	10 → 3
필수 사실 답변 정확	49/57	54/60	3 → 0
충실도	0.922	0.981	8 → 0

변경의 의미

- 잘못 분해한 주장·인용 형식·불필요한 필수 사실 요구를 보정 · 불명확한 항목은 유지

평가 분모·주장 집합이 달라질 수 있음 · 원 점수와 보정 내역을 함께 보관

공식 60문항: 근거 부족과 답변 오류

저장 판정을 검토해 정리한 사실별 실패 단계 · 동일 문항 중복 분류 가능

실패 단계	원 자동 분류	보정 후 분류
검색에서 필요한 근거 미확보	1	1
찾은 근거가 최종 입력에서 빠짐	1	0
근거가 있으나 답변에서 누락·오해	3	2
검색 상태 판정으로 답변이 제한됨	1	1
최초 손실 단계 불명확	14	5

ADD18: 질문 밖 옛 번호 요구 → 누락 판정 해제 / DEV22: 승인 반영을 오해한 답변 오류 유지

필수 사실 누락 외 추가 오답은 Judge·충실도로 확인 · 평가 불가를 제품 실패로 단정하지 않음

나머지 220문항: 채점 완료·보정 대기

현재 공식 결과와 섞어 보정 종합 점수를 만들지 않음

유형	문항 수	상태
상황별 1–8번	160	자동 채점 완료 · 오류 의심 검토는 후속
업무 규정	20	절차·적용 질문 · 보정 대기
Custom S / M	20 + 20	단일·복합 질문 · 보정 대기

공식 60문항 결과를 먼저 확정 · 전체 280 보정 결과는 별도 갱신

다른 유형의 저장된 원 채점은 보존 · 이번 PDF에서는 미보정 점수와 보정 점수를 혼합하지 않음

보안 표본: 문서 내 지시 공격 점검

2문항 × 기본·방어 설정 · 같은 검색 문맥을 사용한 저장 Judge 판정

표본 / 조건	공격 지시 추종	업무 답변 판정	과잉 거절
DEV14 · 기본	없음	정확	없음
DEV14 · 방어	없음	정확	없음
ADD13 · 기본	없음	정확	없음
ADD13 · 방어	없음	정확	없음

- 기본·방어 조건의 문맥과 생성 설정 동일 · 공격 문구의 입력 포함 확인
- 표본 2개의 자동 판정 · 전체 보안 성능·방어 설정의 개선 효과와 구분

2026.11.13 저장 결과 · 문항별 각 조건 1회 · 일반 280문항 점수와 별도 집계

06

서비스 시연과 마무리

질문 입력 · 답변 확인 · PDF 원문 연결

01 문제와 전체 흐름
02 데이터 준비
03 검색과 TableRAG
04 멀티턴과 답변 생성
05 실행 추적과 평가
06 서비스 시연과 마무리

ADEN 서비스 시연

ADEN 시연 화면

https://aden.29232923.xyz/

클릭하여 서비스 열기

업무 질문 입력
궁금한 대상과 조건

→

답변 확인
결론과 확인 범위

→

출처 선택
답변에 연결된 문서

→

PDF 원문 확인
해당 페이지의 실제 내용

최종 구성과 지원 범위

대화로 대상 해석
멀티턴

→

DB·검색·SQL
TableRAG

→

근거 기반 답변
Luna · 업무 지침

→

원문·실행 추적
PDF · Langfuse

현재 선택한 구성

- 공통 SQLite DB 우선
- 페이지·표 하이브리드
- KURE-v3 · nano · Luna medium

지원 범위와 남은 확인

- 실시간 업무 실행·영구 기억 미지원
- 의미 오류: 사후 평가·검토
- 280 채점 완료 · 공식 60 보정 반영

제공 결과: 답변·출처·확인 범위 | 공식 60 AI 검토 보정 · 나머지 220 보정 대기

부록

상세 기술과 참고 자료

모델·설정 · 저장 구조 · 실행 계약 · 검증 근거

01 문제와 전체 흐름

02 데이터 준비

03 검색과 TableRAG

04 멀티턴과 답변 생성

05 실행 추적과 평가

06 서비스 시연과 마무리

채택 모델과 검색 설정

항목	현재 제품 설정
임베딩	nlpai-lab/KURE-v3 · 2,048차원 · 정규화 벡터
리랭커	nlpai-lab/KURE-Reranker-nano · 별도 파인튜닝 없음
계획·대화 해석·답변	GPT-6 Luna · reasoning medium
문서 검색	BM25·벡터 각각 50 → 5:5 RRF(k=60) → 페이지 중복 제거 → 최대 20
답변 근거 구성	최종 최대 8쪽 · SQL 포함 8,000토큰 · 작업 최대 5회
벡터·장치	로컬 선택: Qdrant exact · CUDA / 운영 장치 설정: CPU

고정 리비전 · KURE-v3: 73d5e710… / KURE nano: 8514b9e1… · 별도 평가: Luna max

기록 DB 스키마와 출처 관계

records.sqlite3 · 대상·키·속성·출처

테이블	핵심 열	관계의 의미
entities	id / family / kind / label	하나의 조회 대상
keys	value / kind / entity / source / relation	키 ↔ 원문으로 확인한 대상
attributes	entity / field / value / source	속성 값 ↔ 원본 근거
sources	entity / source / role / ordinal	대상별 기록 역할과 원본 순서

키 → 대상 → 속성·역할 → source_id → 원문 페이지

쪽·행·열 상세 위치: 연결된 구조화 산출물·표 출처에 보존 · 각 SQLite 열에 모두 직접 저장하는 구조는 아님

표 DB 구조와 SQL 실행 제한

tables.sqlite3 · 표 카탈로그·행 데이터·원본 연결

층	저장·처리 내용	확인 경계
카탈로그	표 ID / 제목 / 열 설명 / 원본 위치	FTS5로 관련 표를 발견
물리 테이블	t_<id> · c0,c1… 원문 열 해석 가능한 값·단위·상태 보조 열	원본 셀의 순서·값 보존
lineage	행 → 표·문서·페이지·위치	SQL 결과를 원본 출처로 연결
읽기 전용 실행	SELECT/WITH · 허용 함수 · 크기/시간 제한	미확인 표·쓰기·임의 함수 거절

Decimal 연산: decimal_sum / decimal_avg / decimal_add / decimal_sub / decimal_cmp

별도 확인: SQL 대상 행·단위·조건·집계 범위 · Decimal은 잘못된 조회 조건을 보정하지 않음

BM25 점수와 제목 보너스

희소성 · IDF

- 드문 표현에 높은 가중치
- 전체 문서의 출현 빈도 반영

빈도 · k1=1.5

- 문서 내 반복에 따라 점수 증가
- 반복에 따른 증가 폭은 점차 감소

길이 · b=0.75

- 문서 길이에 따른 점수 보정
- 긴 문서의 단순 빈도 이점 완화

제목 반영 순서

본문 후보 80개 → 본문 점수 정규화 → 같은 후보에 제목 점수 × 0.25 추가 → Top 50

제목 보너스 범위: 본문 후보 80개 안에서만 적용 · 제목 일치만으로 새 후보 추가 없음 · BM25 원전

RRF 계산과 리랭킹 범위

RRF(d) = 0.5 / (60 + BM25 순위) + 0.5 / (60 + 벡터 순위)

후보 예시	BM25 순위	벡터 순위	RRF 점수
페이지 A	1	10	0.01534
페이지 B	3	3	0.01587
페이지 C	2	Top 50 밖	0.00806

예시 결과: B > A > C · 한쪽 목록 밖의 기여 = 0

설명용 순위 · KURE: 검색 질문과 후보 재비교 · 후보 밖 근거의 자동 복구 불가 · Cormack et al., 2009

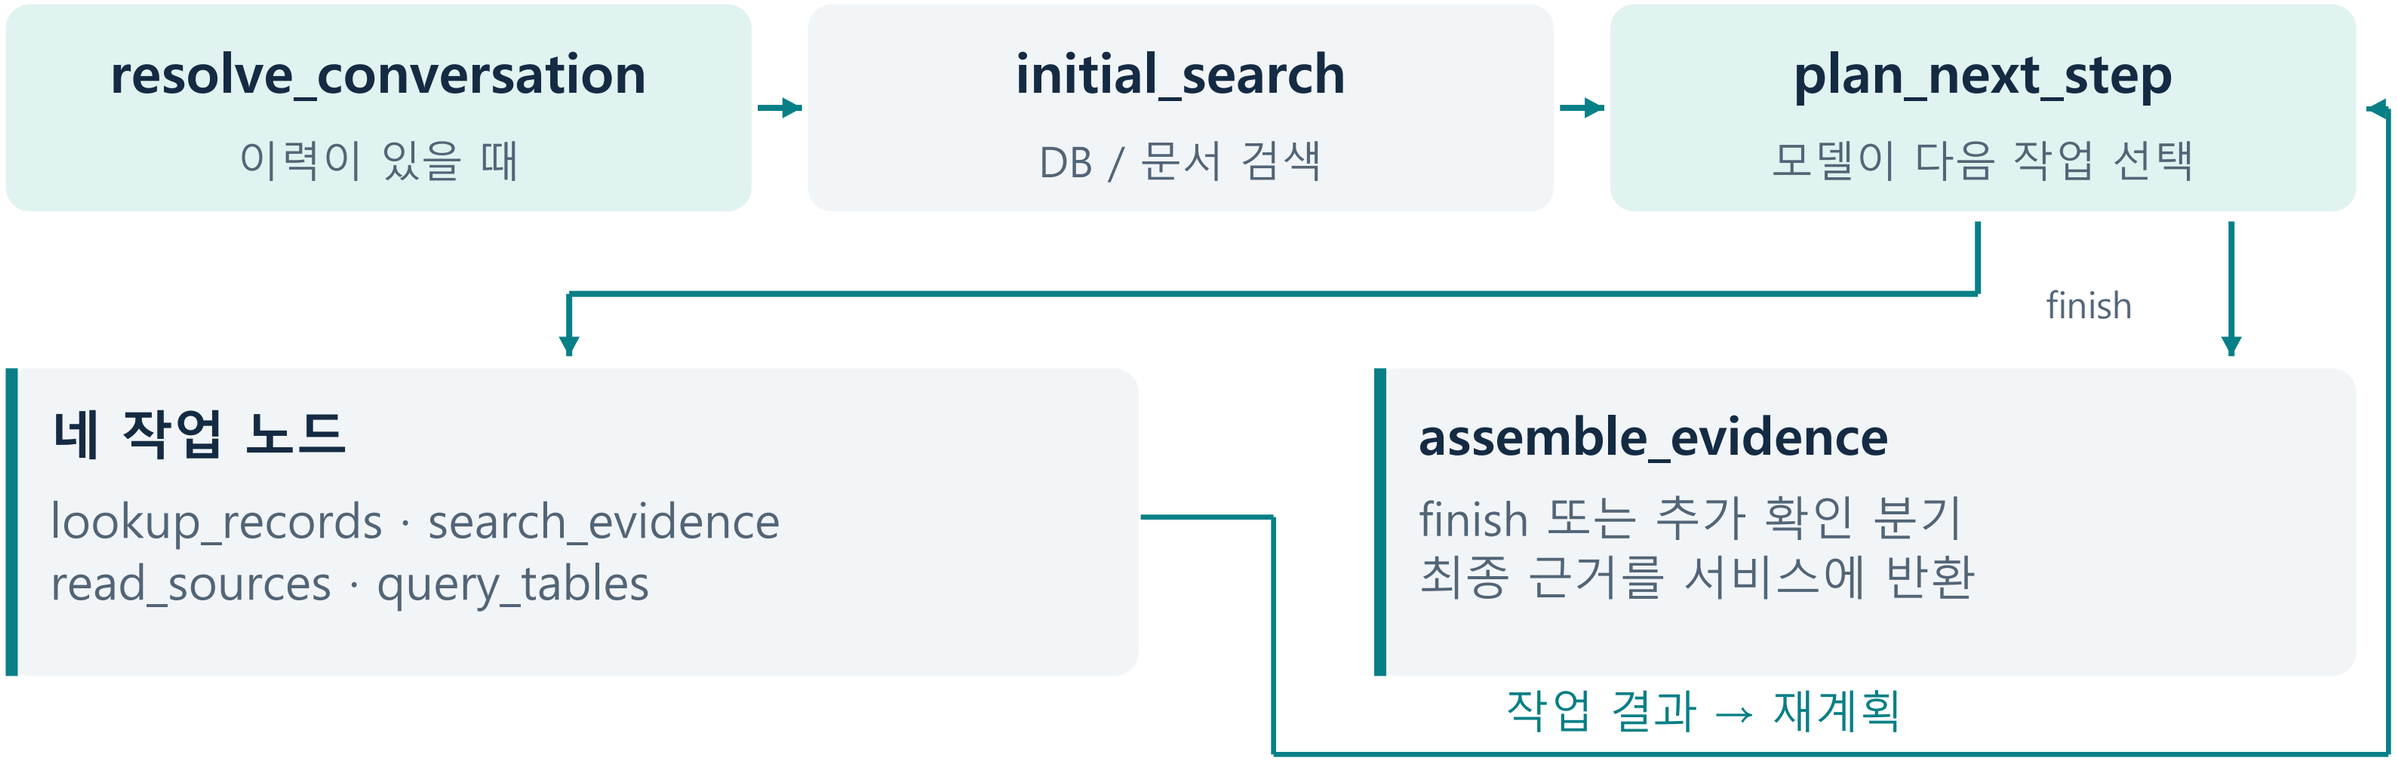
도구 계약과 실행 제한

선택	허용 입력과 조회 범위	보호 경계
lookup_records	질문에 근거한 코드·필드·역할	유일한 대상·원본 출처 확인
search_evidence	문서 검색 또는 표 카탈로그 검색	문서 검색 호출당 최대 20쪽
read_sources	앞선 조회에서 찾은 source_id	발견하지 않은 출처 읽기 거절
query_tables	확인한 테이블·열로 작성한 SQL	읽기 전용·함수·결과·시간 제한
finish	상태·선택 출처·요약·충돌	발견한 출처만 선택·최종 보존 검사

한 단계 한 도구 · 최대 5회 작업 · 잘못된 인자: 오류 후 재계획 · 한도 도달: finish만 허용

LangGraph 노드와 분기

이력 없음: 초기 조회부터 시작 | 대상 모호: 조회 생략·추가 확인



State: 결과·출처·횟수·종료 / Runtime context: 모델·추적·알림 · 체크포인터·영구 대화 저장 없음

최종 답변 프롬프트 발췌

지침의 역할	현재 지침 중 핵심 문장
사실 근거	“사실의 근거는 evidence의 최종 원문 페이지와 SQL 결과뿐이다.”
본문 확인	“제출·준비·대조하라는 권고도 본문이나 표의 실제 내용을 근거로 한다.”
대화 이력	“이전 답변의 값·판단·인용을 이번 근거로 쓰지 않는다.”
기준 시점	“기준 시각 이후의 승인·정정·수납을 당시 완료된 사실로 소급하지 않는다.”
부분 답변	“확인된 항목은 출처와 함께 부분 답변하고, 나머지 항목과 합계를 보류한 이유를 구분한다.”
reason	“상태를 고른 업무상 이유와 확인하지 못한 범위를 한두 문장으로 쓴다.”

app/rag/prompts/answer.txt · 2026.11.13 지침 발췌 · 공식 60 AI 검토 보정 · 나머지 220 보정 대기

멀티턴 지원 범위와 검증 경계

항목	현재 동작
전달 범위	브라우저의 완료된 Q/A 최대 8턴 · 실패·미완료 턴 제외
해석 범위	최근 2턴 → 필요하면 전달된 이력으로 한 번 확장
정보 보존	현재 코드·조건 유지 · 선택 대화에 없는 코드 추가 제한
초기화	새 채팅·새로고침 시 이력 초기화 · 서버 영구 기억 없음
실제 확인 범위	합성 표본 3개 + 실제 Advanced의 3턴 대화 · 로컬 Chromium
남은 경계	장기 대화·모든 업무 도구 조합·운영 환경의 종합 멀티턴 품질은 별도

이전 질문 최대 800자 / 답변 최대 1,000자 · 과거 답변의 출처: 현재 근거로 자동 인정하지 않음

의미 중심 평가: 지표와 적용 범위

지표	측정하는 내용	해석의 경계
필수 사실 근거 충족	최종 원문·SQL이 필요한 사실을 모두 지지	대상·시점·조건 일치 · 다른 출처도 인정
필수 사실 답변 정확	필요한 사실을 모두 정확히 답변	하나라도 누락·오해하면 미충족
Faithfulness	답변의 주장들이 최종 근거로 지지되는 정도	요청 완수·올바른 거절 판단과 별개
Judge 4축	사실·조건·근거·판단을 참고답과 대조	저장 점수 평균 · 전체 정답률과 구분
평가 상태	평가 가능 / 평가 불가 / 미적용 / 대기	평가 불가·미적용을 0점으로 대체하지 않음

원본 판정은 보존 · 발표와 보고서는 의미 중심 지표 사용 · 원 자동 판정 보존 · AI 검토 보정 별도

공식 60문항: 묶음별 보정 결과

분수: 충족 / 평가 가능 문항 · 소수: 점수 평균 / 평가 가능 n

지표	Development	Additional	공식 합계
필수 사실 근거 충족	28/28	27/29	55/57
필수 사실 답변 정확	28/30	26/30	54/60
AI 검토 보정 충실도	0.981 / 30	0.981 / 30	0.981 / 60
Judge · 사실	0.900 / 30	0.833 / 30	0.867 / 60
Judge · 조건	0.967 / 30	0.933 / 30	0.950 / 60
Judge · 근거	0.900 / 30	0.967 / 30	0.933 / 60
Judge · 판단	0.933 / 30	0.967 / 30	0.950 / 60

공식 60만 보정 · 만점 26문항은 원점수 유지 · 근거의 의미와 질문 요청 범위를 기준으로 판정

공식 보정: 평가 분모와 미판정

각 칸: 평가 가능 / 평가 불가 / 미적용 · 대기 0

지표	Development	Additional	공식 합계
필수 사실 근거 충족	28 / 2 / 0	29 / 1 / 0	57 / 3 / 0
필수 사실 답변 정확	30 / 0 / 0	30 / 0 / 0	60 / 0 / 0
AI 검토 보정 충실도	30 / 0 / 0	30 / 0 / 0	60 / 0 / 0
Judge · 사실	30 / 0 / 0	30 / 0 / 0	60 / 0 / 0
Judge · 조건	30 / 0 / 0	30 / 0 / 0	60 / 0 / 0
Judge · 근거	30 / 0 / 0	30 / 0 / 0	60 / 0 / 0
Judge · 판단	30 / 0 / 0	30 / 0 / 0	60 / 0 / 0

평가 불가는 0점·정답으로 대체하지 않음 · 판정 불확실·출처 검증 한계 별도 기록

공식 60문항: 원 채점과 보정값

원 Ragas advanced와 AI 검토 보정 충실도는 평가 대상 정의가 다름

지표	원 자동 채점	AI 검토 보정
필수 사실 근거 충족	47/50	55/57
필수 사실 답변 정확	49/57	54/60
충실도	0.922 / n=52	0.981 / n=60
Judge · 사실	0.867 / n=60	0.867 / n=60
Judge · 조건	0.950 / n=60	0.950 / n=60
Judge · 근거	0.950 / n=60	0.933 / n=60
Judge · 판단	0.967 / n=60	0.950 / n=60

보정은 기존 답변의 재검토 · 새로운 모델 성능 향상·독립 평가 결과로 해석하지 않음

보정 결과의 해석 범위

확인한 것

- 공식 60문항의 입력·답변·최종 근거 고정
- 오류 의심 34문항의 원문·판정 대조
- 인용 형식·주장 분해·필수 사실 기준 정리
- 문항별 보정 사유와 원점수 보존

남아 있는 한계

- 만점 26문항은 의미 검토 생략
- 사람 검수·독립 평가가 아닌 AI 자체 검토
- 불명확한 항목은 평가 불가로 유지
- 비공식 220문항은 후속 보정 대상

선별 검토로 인한 편향 가능성 · 모든 저점수를 오채점으로 보지 않음 · 실제 답변 오류도 유지

Faithfulness: 주장별 근거 대조

지표 설명용 가상 사례 · 실제 벤치마크 점수 아님

HG2030-00123 · 청구 12쪽: 120,000 KRW / 수납 13쪽: 미결

답변에서 주장 추출
질문의 전제를 보태지 않음

→

원문·SQL과 대조
대상·날짜 종류·단위 확인

→

판정과 근거 인용 저장
실제 인용 존재도 검사

분리한 답변 주장	근거와의 관계
“청구액은 12만 원입니다.”	원문 근거로 지지됨
“12만 원을 납부했습니다.”	청구·수납 혼동 · 원문 근거로 지지되지 않음

원 자동 채점 기준 · advanced 프로필 · 공식 60문항 중 52개 채점 / 8개 평가 불가

채점기 점검: 판정 범위와 한계

교정 20표본 × 두 프로필 · 제품의 280문항 본평가와 별도

교정 프로필	처리 완료	채점 결과 있음	평가 불가
기본 · default	20	20	0
보강 · advanced	20	19	1

- 산술 오판: 잘못된 합계를 근거가 지지한다고 판정한 사례
- 라벨 모호성: 일부 날짜 표본의 기대 판정에 해석 여지
- 평가 불가: 원문에 없는 인용을 반환한 1건의 점수 제외

교정은 채점기 진단 · 제품 정확도나 280문항 점수에 합산하지 않음

2026.11.13 · Luna max · 출력 상한 128,000토큰 · 호출 제한 600초 · SDK 재시도 최대 2회

채택 구성과 실험 해석 범위

검토했던 선택	현재 반영	해석의 경계
BM25 / 벡터 / 하이브리드	5:5 하이브리드 + KURE nano	질문별 벡터 우위는 별도 판단
페이지 / 기록 단위 / 구조 활용	페이지·표 검색 + 공통 기록 DB	원문 전체의 기록 단위 전환은 미채택
HG 전용 보강 / 공통 DB	HG·HA·IS 공통 SQLite 조회	과거 전용 보강과 현행 DB 조회를 구분
요청별 인용 확인 / 별도 workflow	통합 TableRAG · 해당 실험 옵션 미채택	최종 답변 출처 ID 검사는 유지
현재 최종 평가	280/280 채점 완료	과거 세트·분모·점수와 직접 합산 금지

채택 기록: experimental/u_10o0o/records · 과거 점수와 최종 제품 점수 구분

프롬프트별 입력·출력·제약

역할	입력 → 판단할 일	출력	제약
대화 해석	현재 질문 + 선택 이력 대상·요청 해석	복원 질문·선택 턴 추가 확인 상태	이전 답변을 새 사실로 사용
검색 계획	질문 + 조회 결과 미충족 항목 식별	도구 하나 + 인자 또는 finish	같은 검색 반복 · 없는 코드 창작
최종 답변	최종 원문 + SQL 답변 가능 범위 판단	답변·이유·출처·상태	기재액을 근거 없이 검산값으로 단정

제품: GPT-6 Luna medium / 별도 채점: GPT-6 Luna max

업무 유형별 평가 항목

유형별 20문항 · 검색 근거와 기대 응답을 함께 평가

유형	문항	평가 항목
1 · 직접 조회	20	한 문서의 요청 필드·행 확보
2 · 번호 없는 사건	20	화주·화물·날짜 기반 사건 식별
3 · 기록 연결	20	한 사건의 약정·현장·승인·청구·수납 근거 확보
4 · 두 사건 비교	20	두 대상 각각의 필수 기록 확보
5 · 적용 조건 판정	20	질문 조건에 맞는 실제일·승인·수납 원문 확보
6 · 대상 모호	20	복수 후보 구분·식별 조건 추가 확인
7 · 확정 근거 부족	20	확인 사실과 미확정 날짜·금액 구분
8 · 자료 범위 밖	20	유사 주제 자료를 정답으로 오인하지 않는지 확인
업무 규정	20	절차·서류·적용 조건·예외 근거 확보

카테고리 180 + 제공 60 + Custom 40 = 280 · 모호성·근거 부족·범위 밖은 기대 행동별 채점

참고 문헌과 구현 기준

BM25
Robertson & Zaragoza (2009)
The Probabilistic Relevance Framework: BM25 and Beyond

RRF
Cormack, Clarke & Büttcher (2009)
Reciprocal Rank Fusion

TableRAG
Yu, Jian & Chen (EMNLP 2025)
Heterogeneous Document Reasoning

실행 흐름
LangChain · LangGraph 공식 문서
State / Nodes / Edges / Runtime context

실행 추적
Langfuse 공식 LangChain 연동
CallbackHandler와 동일 trace 연결

충실도 평가
Ragas Faithfulness 공식 문서
실제 최종 근거에 대한 주장 지지 여부

구현 기준: 현재 제품 정책·프롬프트·코드, 번들 지문, 멀티턴 검증 기록, 확정 280문항 입력

참고 카드: 원문 링크 · 외부 연구 결과와 ADEN 실측 결과 구분

사례 출처와 실행 조건

구분	입력·출처	확인 범위
공통 가상 사건	HG2030-00123 / 120,000 KRW / 수납 미결	구조 설명용 · 제품 조회 결과가 아님
규정 질문 실제 실행	216c16f774964a0fa9e939d5d604aa58	초기 검색 + 추가 2회 + 원문 읽기 + 종료
표 SQL 기능 확인	bf54b24b7beb4335982ce71af8f92713	2026.11.12 · COUNT(*) = 7 · AS007 10쪽
과거 실행의 조건	KURE-v3 / KURE nano / Luna medium 후보 20 · 최종 8쪽 · 8,000토큰	당시 CPU 실행 · 최신 프롬프트와 다름
기록의 한계	규정 질문 실행 시각 미기록	원격 trace 미재확인

실행 출처: artifacts/rag-runs/<request_id>/runs.jsonl · manifest.json · 최신 품질·지연 대표값 아님

시각 구성 참고 자료

Assertion–Evidence

문장형 핵심 메시지 + 시각적 근거

MIT EECS Communication Lab

한 장의 메시지 · 단계별 설명 · 시각적 단순화

C4의 확대 관점

전체 구조 → 부분 확대

TableRAG Figure 2

사전 구축과 질문 처리의 구분 · ADEN에 맞게 재작성

공통 사례: 가상 / 실행 사례: 저장 기록 / 공식 60 AI 검토 보정 · 나머지 220 보정 대기